UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

PROYECTO DE MINERÍA DE DATOS

Estudiantes:

Jesika Victoria Jimenez Prado
Gerard Chaparro Redondo

13 de diciembre de 2025

Introducción **4**
Descripción de los datos originales **6**
Descripción del problema y variable objetivo 6
Tamaño y estructura del conjunto de datos 7
Descripción de las variables y tipo de valores 7
Valores faltantes y su impacto 7
Características estadísticas generales 8
Impacto de las características de los datos en el análisis y el modelado 8
Gráficas importantes para entender el comportamiento del dataset 10
Distribución de la variable base del problema 10
Boxplot de variables numéricas clave 10
Cardinalidad de variables categóricas 11
Evolución temporal de los incidentes 12
Distribución geográfica por región 13
Matriz de correlación de variables numéricas 16
Histogramas globales 18
Descripción del preprocesamiento de los datos **20**
Limpieza inicial y reducción del tamaño del dataset 20
Tratamiento de inconsistencias internas 20
Transformación y validación de información geográfica 21
Creación de la variable objetivo 21
Eliminación de data leakage 21
División en conjuntos de entrenamiento y prueba 21
Imputación de valores faltantes basada en el conjunto de entrenamiento 22
Reducción de cardinalidad 23
Codificación de variables categóricas 23
Tratamiento de outliers y escalado 24
Resultado final del preprocesamiento 24
Modelo Naïve Bayes **26**
Preprocesamiento específico para Naïve Bayes 26
Selección de características 26
Entrenamiento y ajuste de hiperparámetros 27
Evaluación del modelo 27
Discusión del modelo Naïve Bayes 28
Resultados obtenidos con Naïve Bayes 28
Métricas por clase 28
Interpretación global del rendimiento 29
Gráficas y visualizaciones 30
Modelo k-Nearest Neighbors (KNN) **35**
Métricas por clase 36
Discusión del modelo KNN 36
Resultados obtenidos con KNN 37
Métricas por clase 37
Comparación entre validación cruzada y test 38

Gráficas y visualizaciones 39
Support Vector Machines (SVM) 42
Preprocesamiento de los datos para SVM 42
Entrenamiento y ajuste de hiperparámetros 42
Ajuste de hiperparámetros en los modelos SVM 42
Métricas por clase 43
Resultados obtenidos con SVM 44
Gráficas y visualizaciones 44
Árboles de Decisión (Decision Trees) 47
Preprocesamiento de los datos para Árboles de Decisión 47
Entrenamiento y ajuste de hiperparámetros 47
Resultados obtenidos con Árboles de Decisión 48
Bagging (Bootstrap Aggregating) con Árboles de Decisión 50
Descripción general del modelo 50
Entrenamiento y ajuste de hiperparámetros 50
Resultados obtenidos con Bagging 50
Random Forest 52
Descripción general del modelo 52
Entrenamiento y ajuste de hiperparámetros 52
Resultados obtenidos con Random Forest 52
Extra Trees (Extremely Randomized Trees) 54
Descripción general del modelo 54
Entrenamiento y ajuste de hiperparámetros 54
Resultados obtenidos con Extra Trees 54
AdaBoost (Adaptive Boosting) 56
Descripción general del modelo 56
Entrenamiento y ajuste de hiperparámetros 56
Resultados obtenidos con AdaBoost 56
Comparación y conclusiones 58
Tabla comparativa 61
Comparación entre validación cruzada y conjunto de test 62
Hipótesis explicativas de los resultados obtenidos **63**
Evaluación personal final del mejor método 65
Conclusiones 66

Introducción

En los últimos años, el análisis de grandes volúmenes de datos ha adquirido un papel fundamental en la comprensión de fenómenos sociales complejos. En particular, la disponibilidad de bases de datos abiertas relacionadas con movimientos migratorios y crisis humanitarias ha permitido aplicar técnicas de minería de datos y aprendizaje automático con el objetivo de extraer conocimiento útil, identificar patrones relevantes y apoyar la toma de decisiones basada en datos. Dentro de este contexto, el estudio de los incidentes relacionados con migraciones forzadas y sus consecuencias humanas constituye un ámbito de especial interés, tanto desde el punto de vista social como desde la perspectiva analítica.

La presente práctica se enmarca en este escenario y tiene como objetivo principal abordar un problema de clasificación supervisada, cuyo propósito es predecir el nivel de severidad de un incidente migratorio a partir de un conjunto de variables descriptivas. La variable objetivo se define como una categorización discreta con tres niveles de severidad —*Baja*, *Media* y *Alta*— mientras que las variables predictoras incluyen información temporal, geográfica y contextual, como el tipo de incidente, la región y el país de origen, la ruta migratoria, la causa de la muerte o la fuente de información, entre otras. Esta diversidad de atributos da lugar a un conjunto de datos heterogéneo, compuesto tanto por variables numéricas como categóricas, lo que plantea desafíos adicionales en el proceso de modelado.

Uno de los principales retos del problema abordado es el fuerte desbalance de clases presente en la variable objetivo, donde la mayoría de los registros corresponden a incidentes de severidad baja, mientras que los casos de severidad media y alta están claramente infrarepresentados. Este desequilibrio dificulta la construcción de modelos predictivos robustos, ya que los algoritmos tienden a favorecer la clase mayoritaria si no se aplican estrategias adecuadas de preprocesamiento, ajuste de hiperparámetros o evaluación. Por este motivo, a lo largo de la práctica se presta especial atención al uso de métricas de evaluación apropiadas, como el *F1-score ponderado*, así como a técnicas de balanceo y ponderación de clases.

El desarrollo del trabajo sigue una metodología estructurada que abarca todas las fases habituales de un proyecto de minería de datos. En primer lugar, se realiza un preprocesamiento exhaustivo de los datos, que incluye la imputación de valores faltantes, la codificación de variables categóricas mediante *One-Hot Encoding*, el escalado de variables numéricas cuando es necesario y la selección de características relevantes para reducir la dimensionalidad y eliminar ruido. Estas etapas son fundamentales para garantizar que los modelos puedan aprender patrones significativos de forma eficiente y estable.

A continuación, se entrenan y evalúan distintos algoritmos de clasificación, representativos de diferentes familias de modelos. En concreto, se analizan métodos probabilísticos como Naïve Bayes, algoritmos basados en distancias como K-Nearest Neighbors, modelos lineales y no lineales basados en márgenes como Support Vector Machines, y modelos basados en árboles de decisión, tanto individuales como combinados mediante técnicas de *ensemble learning*. Entre estas últimas se incluyen Decision Trees, Bagging, Random Forest, Extra Trees y AdaBoost, lo que permite estudiar el impacto de la agregación de modelos en la capacidad predictiva y la generalización.

La comparación sistemática entre estos algoritmos se realiza empleando validación cruzada estratificada, ajuste de hiperparámetros mediante *Grid Search* y un análisis detallado de métricas de rendimiento, informes de clasificación y matrices de confusión. Este enfoque permite no solo identificar el modelo con mejor rendimiento global, sino también analizar el comportamiento de cada algoritmo frente a las distintas clases de severidad, poniendo especial énfasis en la capacidad de detección de los casos más críticos.

En definitiva, esta práctica tiene como finalidad no solo construir modelos predictivos precisos, sino también comprender las ventajas y limitaciones de cada enfoque, evaluar el impacto del preprocesamiento y del desbalance de clases, y extraer conclusiones fundamentadas sobre la idoneidad de los distintos algoritmos en un problema realista y socialmente relevante. El trabajo pone de manifiesto la importancia de una metodología rigurosa en proyectos de aprendizaje automático y demuestra cómo la combinación de técnicas adecuadas puede mejorar significativamente la calidad de las predicciones en contextos complejos.

Descripción de los datos originales

El conjunto de datos utilizado en este proyecto fue obtenido a través de la plataforma Kaggle, a partir del repositorio público disponible en el siguiente enlace: https://www.kaggle.com/datasets/nelgiriyewithana/global-missing-migrants-dataset

Este dataset corresponde al **Global Missing Migrants Dataset**, una base de datos que recopila información sobre incidentes migratorios a nivel mundial en los que se han registrado personas migrantes fallecidas o desaparecidas. Cada fila del conjunto de datos representa un evento migratorio individual, documentado a partir de diversas fuentes oficiales y organizaciones internacionales. El periodo temporal cubierto por los datos abarca desde el año 2014 hasta 2023.

Descripción del problema y variable objetivo

El problema abordado en este proyecto es un problema de clasificación, cuyo objetivo es estimar la severidad de un incidente migratorio en función de su impacto humano. Dicho impacto se mide a través del número total de personas fallecidas y desaparecidas durante cada evento.

El dataset original no incluye una variable categórica que represente directamente la severidad del incidente. Por esta razón, se definió una nueva **variable objetivo** denominada **"Severidad"**, construida a partir de la variable numérica "Total Number of Dead and Missing", que indica el total de víctimas (fallecidos y desaparecidos) asociadas a cada incidente.

Para la creación de esta variable objetivo se establecieron **cortes realistas** basados en el número total de víctimas, en lugar de utilizar percentiles, con el fin de mantener una interpretación semántica clara de cada clase. Las clases de severidad se definieron de la siguiente manera:

- **Severidad Baja**: entre 0 y 2 personas fallecidas o desaparecidas.
- **Severidad Media**: entre 3 y 10 personas fallecidas o desaparecidas.
- **Severidad Alta**: más de 10 personas fallecidas o desaparecidas.

Esta discretización permite transformar el problema original en un escenario de clasificación multiclase, alineado con los objetivos del proyecto.

Tamaño y estructura del conjunto de datos

En su forma original, el dataset cuenta con 13.020 registros y 19 variables, combinando atributos numéricos y categóricos. La estructura general del conjunto de datos es la siguiente:

- **Variables categóricas (11)**: describen el tipo de incidente, la localización geográfica, la ruta migratoria, la causa de la muerte y la fuente de información, entre otros aspectos.

- **Variables numéricas (8)**: recogen información cuantitativa relacionada con el número de víctimas, sobrevivientes y la distribución por género y edad.

Descripción de las variables y tipo de valores

Las variables numéricas incluyen, entre otras:

El año del incidente, el número de personas fallecidas, el número estimado de personas desaparecidas, el total de fallecidos y desaparecidos, así como el número de sobrevivientes, mujeres, hombres y niños involucrados en cada evento. Estas variables presentan una alta dispersión y rangos amplios, con valores máximos elevados, reflejando la existencia de incidentes de gran magnitud.

Las variables categóricas presentan una alta cardinalidad en algunos casos, especialmente en atributos como: *Location of death*, *Information Source* y *Coordinates*, lo que puede tener un impacto significativo en las etapas posteriores de preprocesamiento y codificación de los datos.

Valores faltantes y su impacto

El conjunto de datos presenta valores faltantes en varias variables, aunque la mayoría de las columnas se encuentran casi completas. Destacan especialmente:

- **Number of Dead**: 550 valores faltantes.

- **Migration route**: 3.021 valores faltantes.

- **Coordinates**: 36 valores faltantes.

- **Region of Origin**, **Country of Origin** e **Information Source**: con un número reducido de valores ausentes.

La presencia de valores faltantes puede afectar tanto el análisis exploratorio como el rendimiento de los modelos de clasificación, especialmente en variables clave relacionadas con la localización geográfica y el número de víctimas. Por ello, fue necesario considerar estrategias de tratamiento de valores faltantes durante la fase de preprocesamiento.

Características estadísticas generales

El análisis estadístico descriptivo muestra que las variables relacionadas con el número de víctimas presentan una distribución altamente asimétrica, con valores de skewness positivos muy elevados, lo que indica una fuerte concentración de incidentes de baja magnitud y un número reducido de eventos extremadamente severos.

Asimismo, se identificó la presencia de outliers en la mayoría de las variables numéricas, lo cual es coherente con la naturaleza del fenómeno estudiado, donde existen incidentes excepcionales con un impacto humano muy superior al promedio.

Finalmente, el análisis de correlación muestra que la variable “Total Number of Dead and Missing” presenta una fuerte correlación con otras variables numéricas relacionadas con víctimas, como el número estimado de personas desaparecidas y el número de fallecidos, lo que confirma su idoneidad como base para la definición de la variable objetivo de severidad.

```
--- DESCRIPTIVE STATISTICS (NUMERIC) ---
       Incident year  Number of Dead  Minimum Estimated Number of Missing  Total Number of Dead and Missing  Number of Survivors  Number of Females  Number of Males  Number of Children
count      13020.000       12470.000                            13020.000                         13020.000            13020.000          13020.000        13020.000           13020.000
mean        2019.061           2.624                                1.904                             4.417                6.554              0.458            1.116               0.238
std            2.419           9.728                               15.645                            19.951               42.315              2.854            3.811               2.417
min         2014.000           0.000                               -2.000                             1.000               -2.000              0.000            0.000               0.000
25%         2017.000           1.000                                0.000                             1.000                0.000              0.000            0.000               0.000
50%         2019.000           1.000                                0.000                             1.000                0.000              0.000            1.000               0.000
75%         2021.000           2.000                                0.000                             2.000                0.000              0.000            1.000               0.000
max         2023.000         750.000                              750.000                          1022.000             1950.000             94.000          135.000             250.000
```

Impacto de las características de los datos en el análisis y el modelado

El conjunto de datos presenta varias características que influyen directamente en las decisiones de preprocesamiento y en el rendimiento de los modelos de clasificación utilizados posteriormente.

En primer lugar, las distribuciones altamente asimétricas de las variables numéricas relacionadas con el número de víctimas (fallecidos, desaparecidos y sobrevivientes) reflejan la naturaleza real del fenómeno estudiado: la mayoría de los incidentes involucran un número reducido de personas, mientras que un número pequeño de eventos concentra un impacto humano extremadamente elevado. Esta fuerte asimetría puede afectar negativamente a modelos sensibles a la distribución de los datos, especialmente aquellos basados en distancias o en supuestos de normalidad, por lo que resulta necesario considerar técnicas como transformaciones, escalado robusto o el uso de algoritmos menos sensibles a este problema.

En segundo lugar, se observa la presencia de un número significativo de outliers en casi todas las variables numéricas. Estos valores extremos corresponden a incidentes de gran magnitud y no deben interpretarse necesariamente como errores de medición, sino como eventos excepcionales pero reales. No obstante, su existencia puede distorsionar medidas estadísticas tradicionales como la media y la desviación estándar, así como influir de forma desproporcionada en el proceso de entrenamiento de algunos modelos. Por este motivo, se requiere una evaluación cuidadosa para decidir si estos valores deben mantenerse, transformarse o tratarse de forma específica durante el preprocesamiento.

Otro aspecto relevante es la alta cardinalidad de varias variables categóricas, como Location of death, Information Source y Coordinates. Este elevado número de categorías puede incrementar significativamente la dimensionalidad del conjunto de datos al aplicar técnicas de codificación como one-hot encoding, lo que a su vez puede provocar problemas de sobreajuste y aumentar el coste computacional. En consecuencia, resulta necesario aplicar estrategias de reducción de cardinalidad, agrupación de categorías poco frecuentes o codificaciones alternativas más eficientes.

Asimismo, la presencia de valores faltantes en determinadas variables introduce incertidumbre y puede generar sesgos si no se trata adecuadamente. En variables clave como Number of Dead o Migration route, la ausencia de datos puede afectar tanto a la creación de nuevas variables como a la capacidad predictiva del modelo. Por ello, el tratamiento de valores faltantes constituye una etapa fundamental del preprocesamiento, ya sea mediante imputación, eliminación selectiva o la creación de categorías específicas para valores desconocidos.

Finalmente, el análisis de correlación entre variables numéricas revela una fuerte relación entre la variable base utilizada para definir la severidad (Total Number of Dead and Missing) y otras variables asociadas al número de víctimas. Este alto grado de correlación implica que algunas variables pueden aportar información redundante, lo que puede afectar a la interpretabilidad del modelo y aumentar el riesgo de multicolinealidad en determinados algoritmos. En consecuencia, resulta conveniente evaluar la selección de características para evitar redundancias y mejorar la eficiencia del modelo.

En conjunto, estas características evidencian que el dataset, aunque rico en información y altamente representativo del fenómeno estudiado, requiere un preprocesamiento cuidadoso antes de aplicar técnicas de clasificación, con el fin de garantizar resultados robustos, interpretables y generalizables.

Gráficas importantes para entender el comportamiento del dataset

Distribución de la variable base del problema

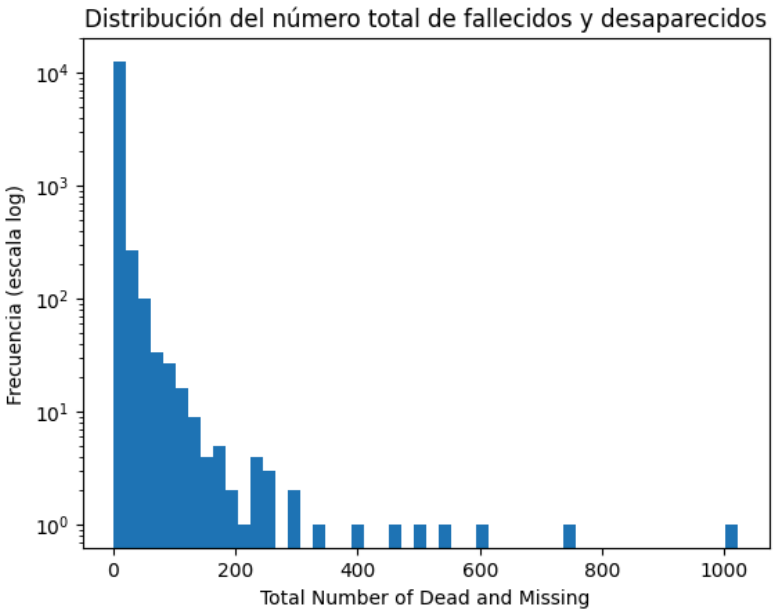

La distribución presenta una fuerte asimetría positiva, con una alta concentración de eventos de baja magnitud y una cola larga asociada a incidentes excepcionales.

Boxplot de variables numéricas clave

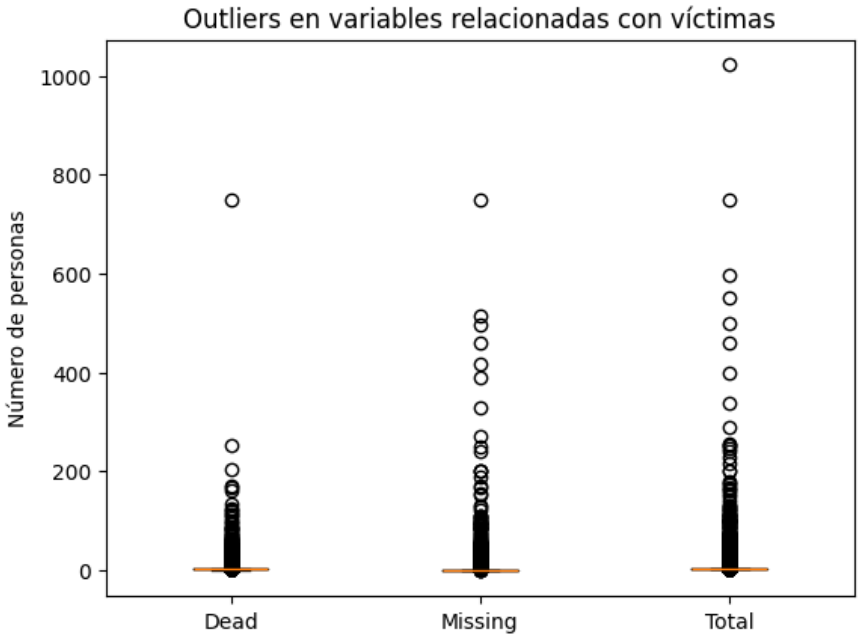

En las tres categorías, la mayoría de los datos están concentrados en valores bajos (cerca de cero), pero existen valores atípicos muy altos, lo que sugiere que hay eventos o casos específicos con un número significativamente mayor de víctimas.

La categoría "Total" tiene la mayor dispersión y los outliers más extremos, lo que es lógico, ya que combina las categorías de fallecidas y desaparecidas.

Cardinalidad de variables categóricas

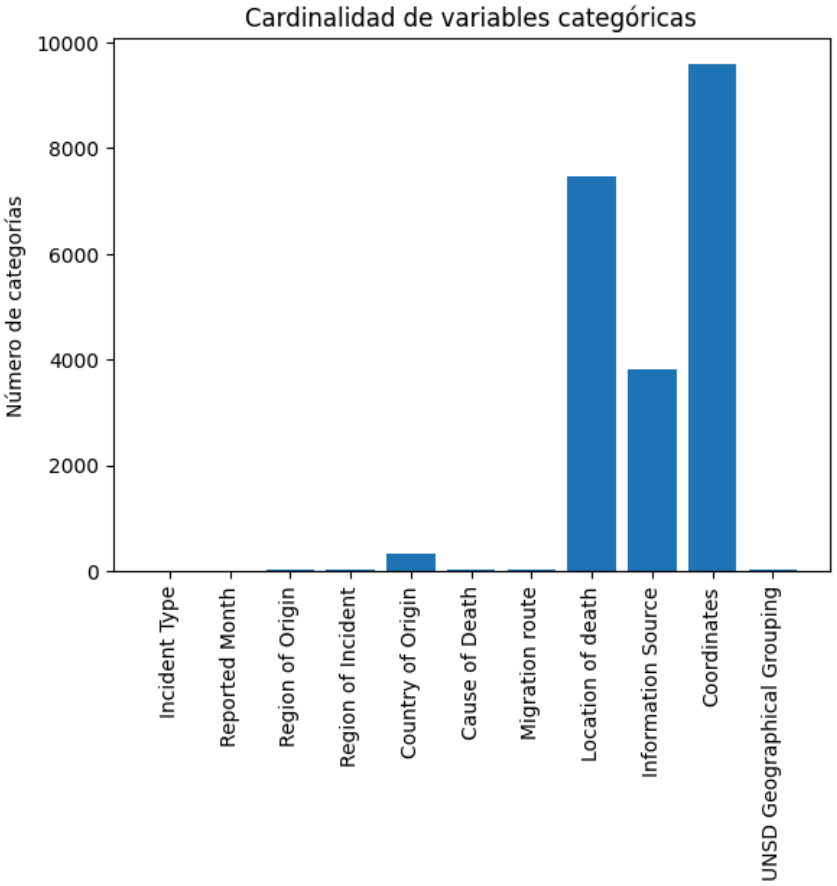

Las variables como "Migration Route", "Location of Death", "Coordinates", y "UNSD Geographical Grouping" tienen una alta cardinalidad, lo que significa que hay una gran diversidad de categorías únicas en estas variables.

Las variables como "Incident Type", "Reported Month", y "Region of Origin" tienen una baja cardinalidad, lo que sugiere que hay pocas categorías únicas en estas variables.

Evolución temporal de los incidentes

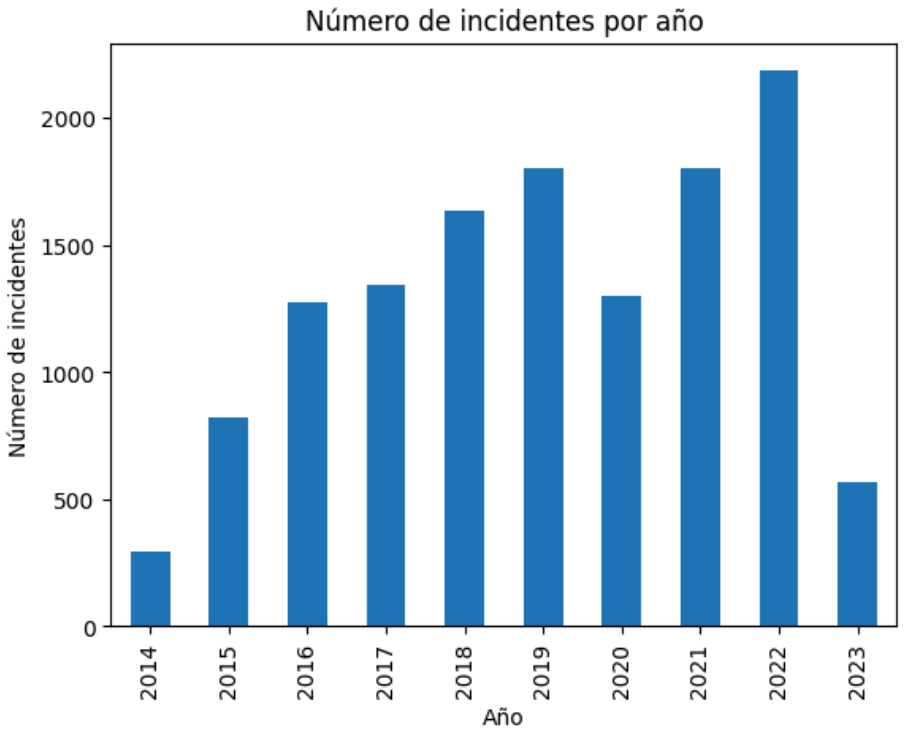

En 2014, el número de incidentes fue notablemente bajo, alrededor de 300, pero experimentó un aumento significativo en los años siguientes, alcanzando aproximadamente 1,300 en 2015 y manteniendo un crecimiento gradual hasta llegar a su primer pico en 2019, con cerca de 1,800 incidentes. En 2020, se observó una disminución, posiblemente relacionada con cambios globales como la pandemia, reduciéndose a alrededor de 1,300 incidentes. Sin embargo, la cifra volvió a subir en 2021 y alcanzó su máximo en 2022, con más de 2,000 incidentes, el valor más alto registrado en todo el período. Finalmente, en 2023, hubo un descenso abrupto, situándose en aproximadamente 600 incidentes, el nivel más bajo desde 2015. Esta variación sugiere la influencia de factores externos o cambios en las condiciones que afectaron la frecuencia de los incidentes a lo largo de los años.

Distribución geográfica por región

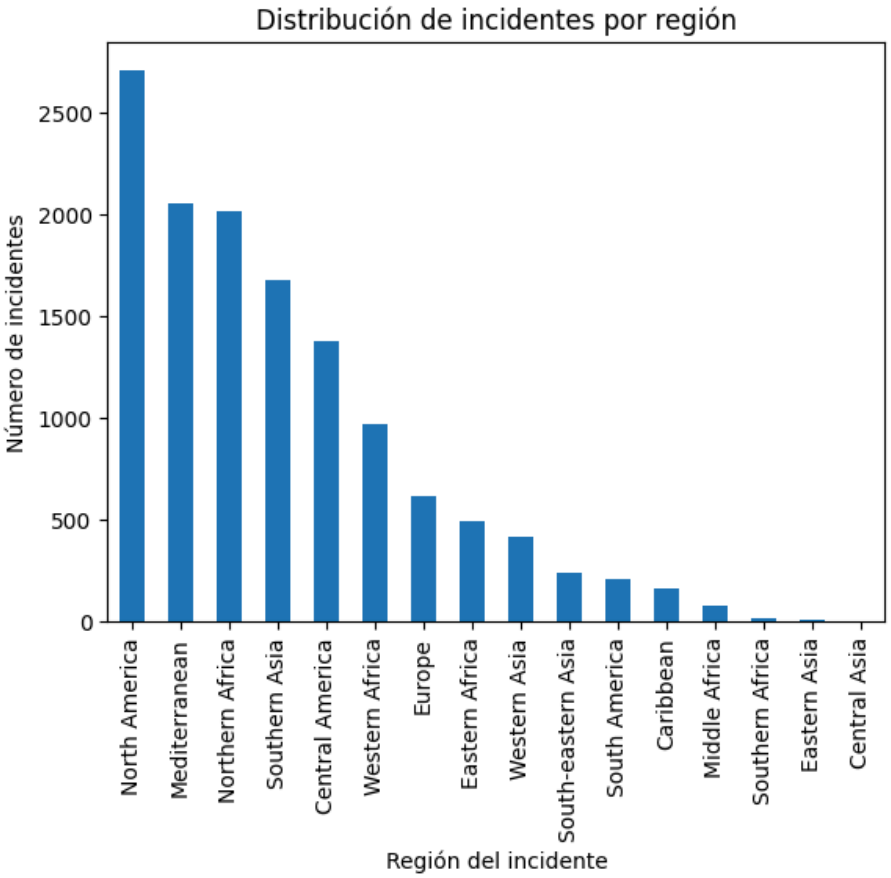

Esta gráfica de barras ilustra la distribución de incidentes por región, mostrando una clara concentración geográfica en ciertas áreas del mundo.
North America (América del Norte) encabeza la lista con el mayor número de incidentes, superando los 2,500 casos, seguida de cerca por la región del Mediterranean (Mediterráneo) y Northern Africa (África del Norte), ambas con alrededor de 2,000 incidentes cada una.

Southern Asia (Asia del Sur) también presenta una cifra significativa, aunque menor, con aproximadamente 1,500 incidentes.

Otras regiones como Central America (América Central) y Western Africa (África Occidental) registran entre 1,000 y 1,500 incidentes, mientras que Europe (Europa) y Eastern Africa (África Oriental) muestran cifras más moderadas, alrededor de 500 a 1,000 incidentes. Las regiones con menor número de incidentes incluyen Western Asia (Asia Occidental), South-eastern Asia (Sudeste Asiático), South America (América del Sur), Caribbean (Caribe), Middle Africa (África Central), Eastern Asia (Asia Oriental), y Central Asia (Asia Central), todas con valores notablemente más bajos, incluso cercanos a cero en algunos casos. Esta distribución refleja una desigualdad regional en la frecuencia de incidentes, destacando áreas específicas con una mayor concentración de eventos.

Causas de muerte más frecuentes de muertes

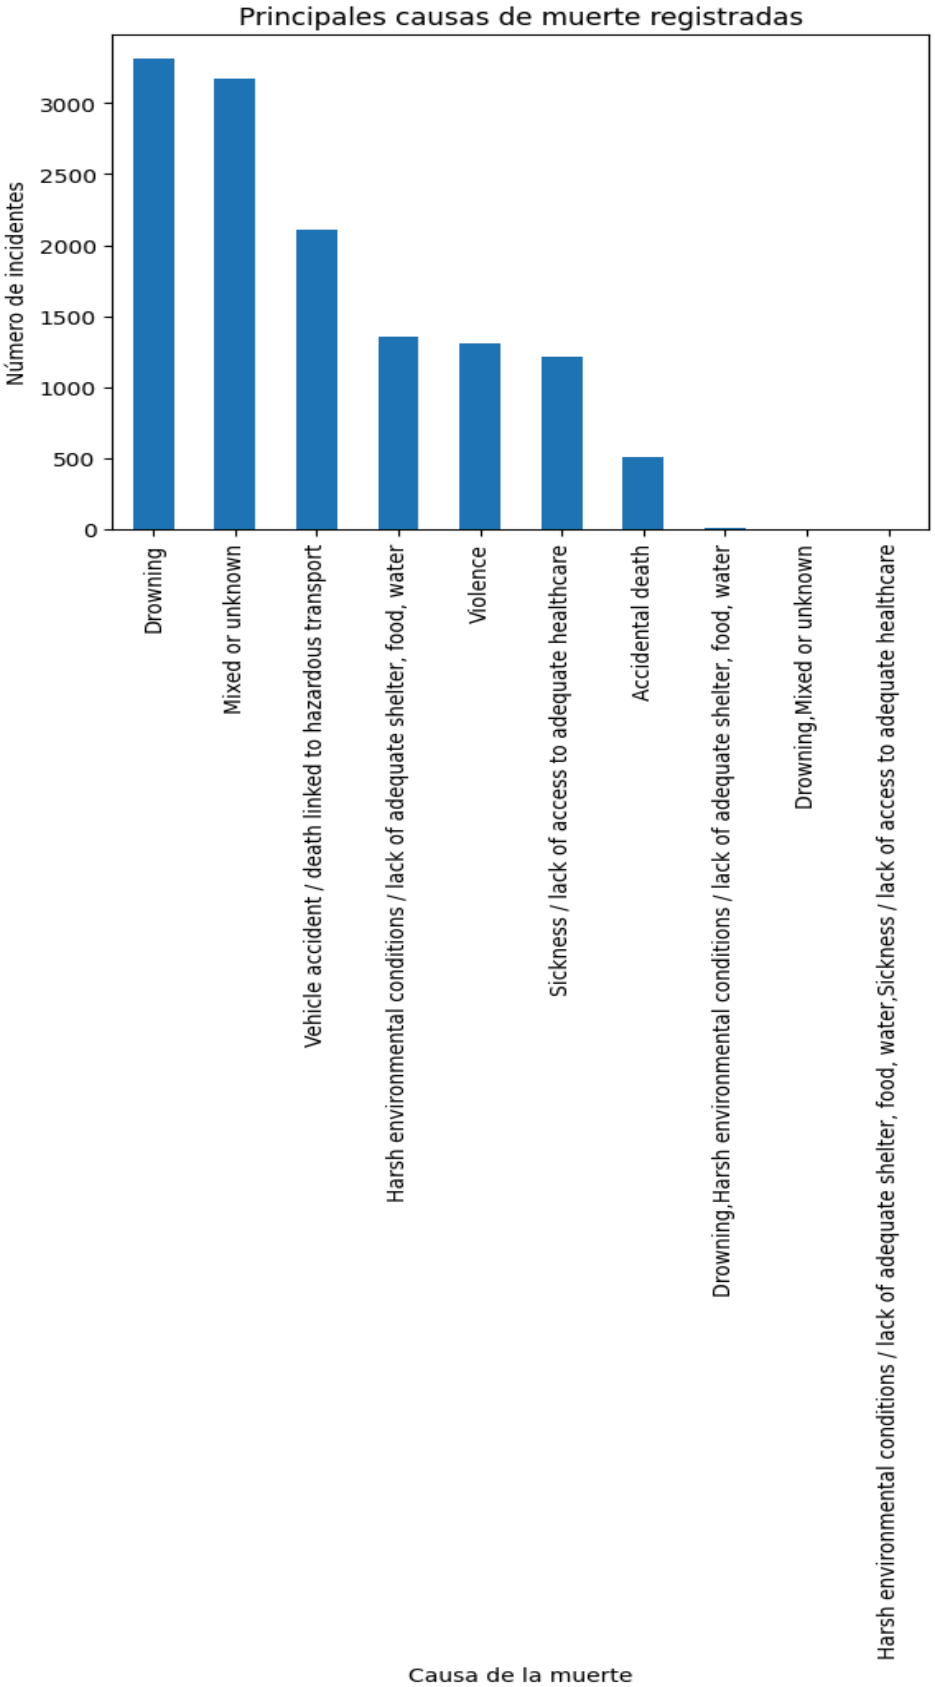

Esta gráfica de barras presenta las principales causas de muerte registradas, destacando una marcada diferencia en la frecuencia de cada una.

La causa más común es "Drowning or unknown" (Ahogamiento o desconocida), con más de 3,000 incidentes registrados, seguida de cerca por "Mixed or unknown" (Mixta o desconocida), que también supera los 3,000 casos.

La tercera causa más frecuente es "Vehicle accident / death linked to hazardous transport" (Accidente vehicular o muerte vinculada al transporte peligroso), con alrededor de 2,000 incidentes. Otras causas relevantes incluyen "Harsh environmental conditions / lack of adequate shelter, food, water" (Condiciones ambientales adversas o falta de refugio, comida y agua adecuados) y "Violence" (Violencia), ambas con aproximadamente 1,500 incidentes cada una.

La categoría "Sickness / lack of access to adequate healthcare" (Enfermedad o falta de acceso a atención médica adecuada) registra cerca de 1,000 casos, mientras que "Accidental death" (Muerte accidental) presenta una cifra menor, alrededor de 500 incidentes.

Finalmente, las categorías menos frecuentes son "Drowning, Harsh environmental conditions, sickness / lack of access to adequate healthcare" y "Mixed" (Mixta), con valores casi insignificantes. Este patrón refleja que las causas más comunes de muerte están relacionadas con ahogamientos, condiciones desconocidas o mixtas, y accidentes de transporte, mientras que otras causas, aunque presentes, son menos frecuentes.

Matriz de correlación de variables numéricas

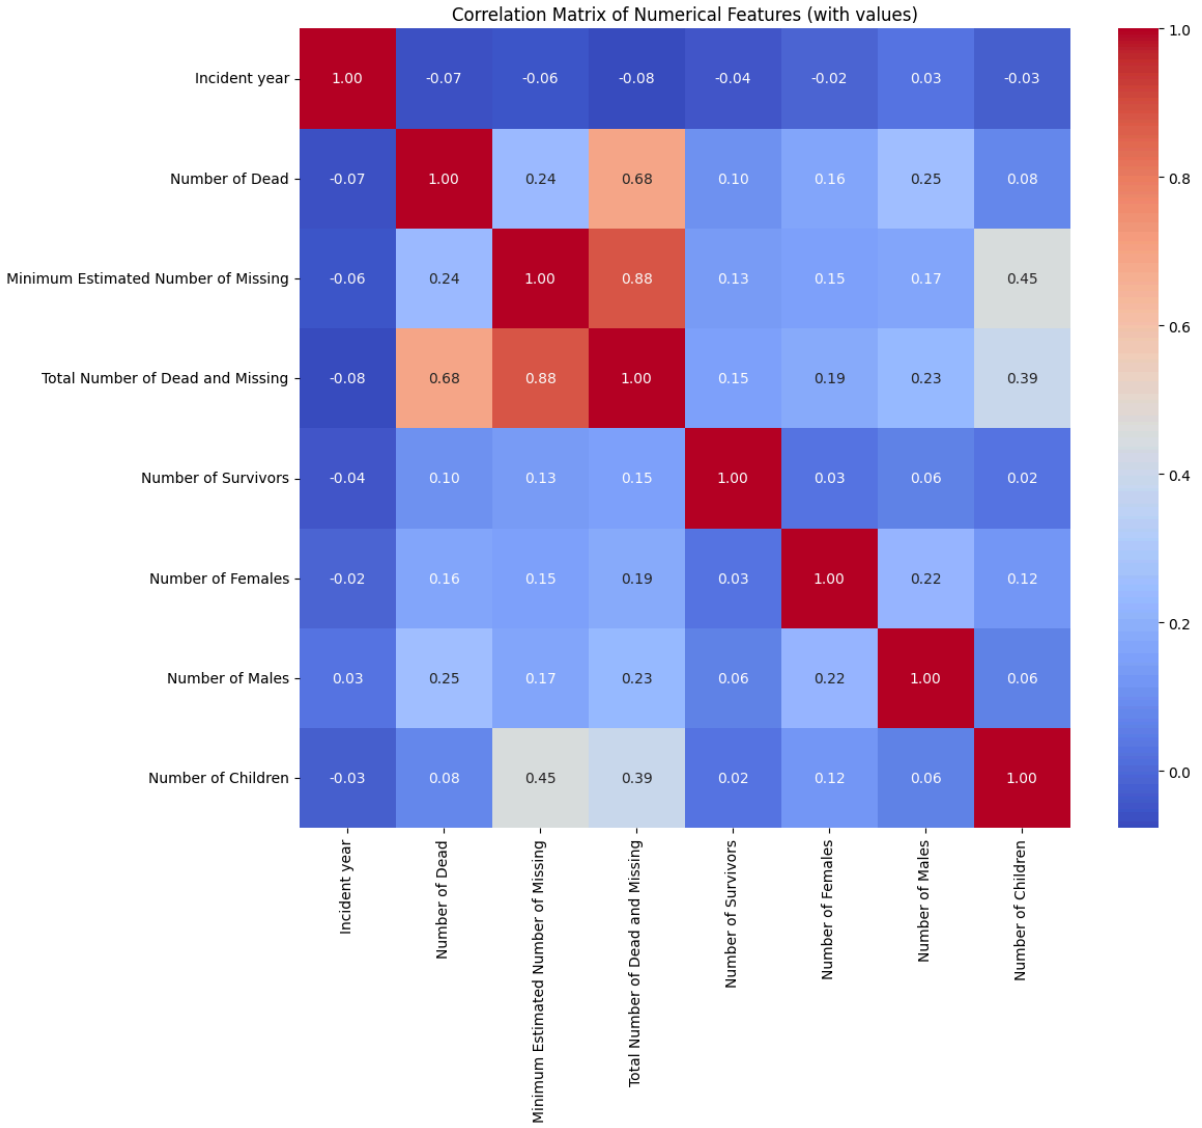

Esta matriz de correlación visualiza las relaciones lineales entre diferentes variables numéricas relacionadas con incidentes, utilizando un código de colores para representar la fuerza y dirección de las correlaciones, donde el rojo indica una correlación positiva fuerte (cercana a 1), el azul claro o blanco indica una correlación débil o nula (cercana a 0), y los tonos intermedios reflejan correlaciones moderadas.

La variable "Incident year" (Año del incidente) muestra correlaciones casi nulas con todas las demás variables, lo que sugiere que el año en que ocurrió el incidente no está linealmente relacionado con el número de víctimas, supervivientes o grupos demográficos afectados. En contraste, las variables "Number of Dead" (Número de fallecidos), "Minimum Estimated Number of Missing" (Número mínimo estimado de desaparecidos), y "Total Number of Dead and Missing" (Número total de fallecidos y desaparecidos) presentan correlaciones positivas fuertes entre sí, especialmente entre "Number of Dead" y "Total Number of Dead and Missing" (0.68), y entre "Minimum Estimated Number of Missing" y "Total Number of Dead and Missing" (0.88). Esto indica que, a mayor número de fallecidos o desaparecidos, mayor es el total combinado de víctimas.

Las variables relacionadas con los supervivientes y los grupos demográficos, como "Number of Survivors" (Número de supervivientes), "Number of Females" (Número de mujeres), "Number of Males" (Número de hombres), y "Number of Children" (Número de niños), muestran correlaciones positivas moderadas entre sí, pero bajas con las variables de víctimas. Por ejemplo, el "Number of Survivors" tiene una correlación baja con el "Number of Dead" (0.10), lo que sugiere que el número de supervivientes no está fuertemente relacionado con el número de fallecidos. Finalmente, la correlación más alta dentro de los grupos demográficos se observa entre "Number of Males" y "Number of Females" (0.22), aunque sigue siendo moderada.

En resumen, las variables relacionadas con víctimas (fallecidos y desaparecidos) están fuertemente correlacionadas entre sí, mientras que las variables demográficas y de supervivientes muestran correlaciones más bajas y moderadas, tanto entre ellas como con las variables de víctimas.

Histogramas globales

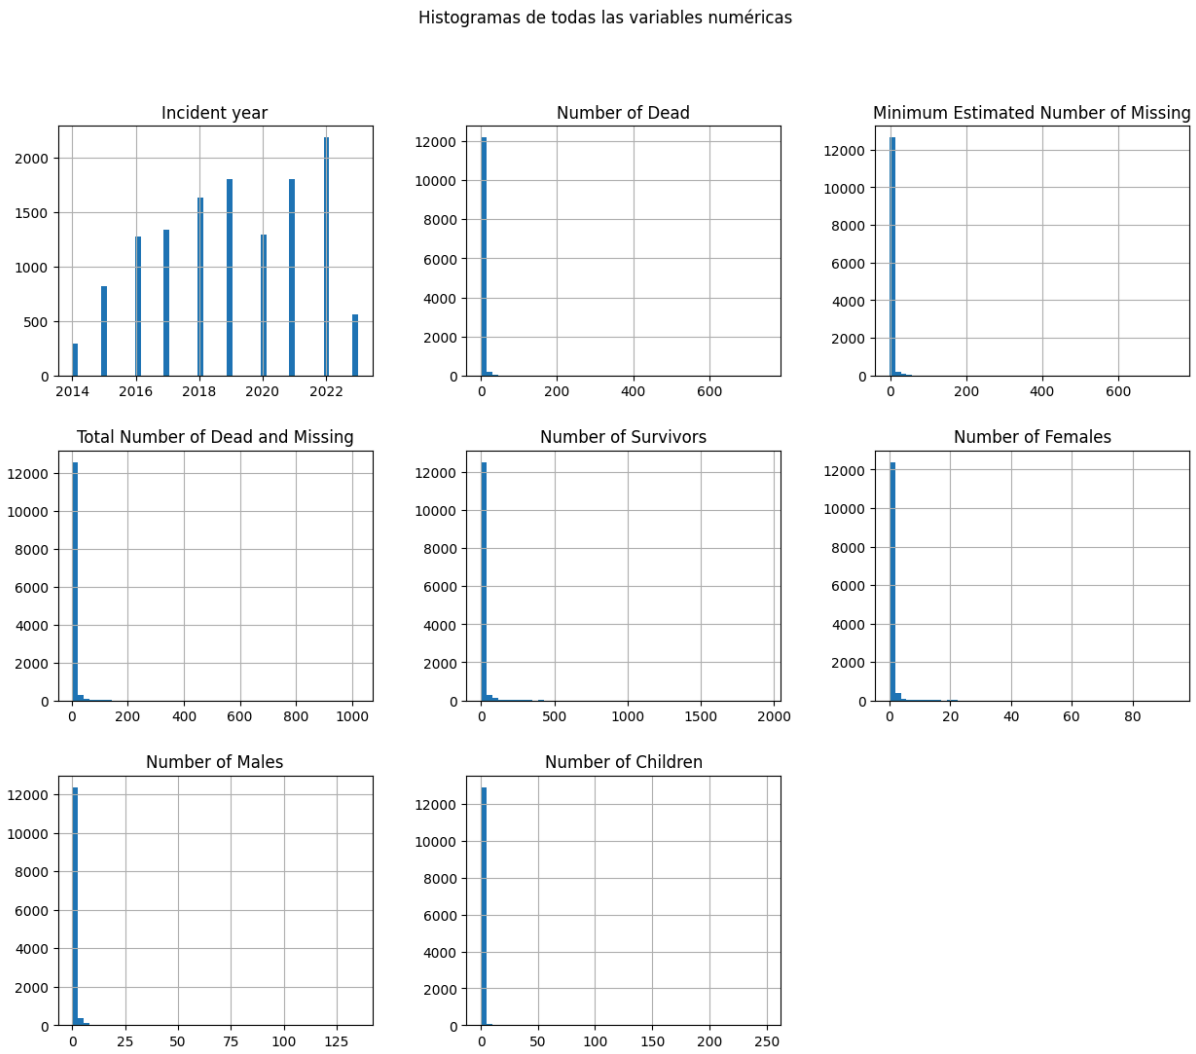

Esta colección de histogramas muestra la distribución de varias variables numéricas relacionadas con incidentes, revelando patrones interesantes en cada una de ellas.

El histograma de "Incident year" (Año del incidente) presenta una distribución que abarca desde 2014 hasta 2023, con una mayor frecuencia de incidentes registrados entre 2016 y 2022, destacando un pico notable en 2022. En cuanto a las variables "Number of Dead" (Número de fallecidos), "Minimum Estimated Number of Missing" (Número mínimo estimado de desaparecidos), y "Total Number of Dead and Missing" (Número total de fallecidos y desaparecidos), todas muestran una distribución altamente sesgada hacia la izquierda, con la mayoría de los valores concentrados cerca de cero y una cola larga hacia valores más altos. Esto sugiere que, aunque la mayoría de los incidentes registran un número bajo de víctimas, existen algunos casos excepcionales con cifras significativamente altas.

Las variables relacionadas con los supervivientes y grupos demográficos, como "Number of Survivors" (Número de supervivientes), "Number of Females" (Número de mujeres), "Number of Males" (Número de hombres), y "Number of Children" (Número de niños), también exhiben una distribución sesgada hacia la izquierda. En todos estos casos, la mayoría de los incidentes tienen valores cercanos a cero, pero hay algunos incidentes con cifras más altas, aunque menos frecuentes. Esto indica que, en la mayoría de los incidentes, el número de supervivientes y de personas afectadas por grupo demográfico es bajo, pero existen casos atípicos con cifras más elevadas.

En resumen, los histogramas reflejan que la mayoría de los incidentes registran un número bajo de víctimas, supervivientes y grupos demográficos afectados, pero también destacan la presencia de casos excepcionales con cifras significativamente altas, especialmente en las variables relacionadas con víctimas.

Descripción del preprocesamiento de los datos

En esta sección se describen de forma detallada todas las etapas de preprocesamiento aplicadas al conjunto de datos original, justificando cada decisión en base a los resultados obtenidos durante el análisis exploratorio y las transformaciones realizadas.

Limpieza inicial y reducción del tamaño del dataset

El dataset original contaba con 13.020 registros y 19 variables. En una primera fase se llevó a cabo una limpieza básica orientada a eliminar redundancias y errores evidentes:

- **Eliminación de duplicados**: Se detectaron 641 registros duplicados, que fueron eliminados para evitar una sobre-representación de determinados eventos. Esta operación redujo el tamaño del dataset a 12.379 registros.

- **Corrección de valores numéricos inválidos**: Durante el análisis exploratorio se observaron valores negativos en variables como Minimum Estimated Number of Missing y Number of Survivors, con mínimos de −2. Dado que estos valores carecen de sentido semántico, se identificaron 4 valores negativos en cada una de estas variables, los cuales fueron reemplazados por valores nulos (NaN) para su posterior imputación.

Tratamiento de inconsistencias internas

El análisis de coherencia entre variables relacionadas con el número de víctimas reveló la existencia de inconsistencias lógicas:

- **Corrección del total de fallecidos y desaparecidos**: En 4 registros, el valor de Total Number of Dead and Missing era inferior a la suma de fallecidos y desaparecidos. En estos casos, el total fue corregido automáticamente utilizando dicha suma.

- **Eliminación de registros incoherentes**: Aunque no se detectaron casos imposibles del tipo “total igual a cero con fallecidos positivos”, sí se identificaron 899 registros en los que la suma de mujeres, hombres y niños superaba el total de víctimas. Estos registros fueron eliminados por ser internamente contradictorios.

Tras esta fase de limpieza, el dataset quedó reducido a 11.480 registros, lo que representa una reducción aproximada del 12 % respecto al conjunto original, a cambio de una mejora significativa en la coherencia de los datos.

Transformación y validación de información geográfica

La variable Coordinates contenía 36 valores faltantes y estaba almacenada como texto. Esta variable fue transformada en dos nuevas columnas numéricas (Latitude y Longitude), validando los rangos geográficos permitidos. No se detectaron coordenadas mal formateadas, y la columna original fue eliminada tras la transformación.

Creación de la variable objetivo

La variable objetivo “Severidad” se construyó a partir de Total Number of Dead and Missing. El análisis estadístico mostró una distribución altamente concentrada en valores bajos (mediana = 1, percentil 75 = 2, máximo = 1022), lo que justificó el uso de cortes semánticos realistas en lugar de percentiles.

La distribución final de la variable objetivo mostró un fuerte desbalance:

- Baja: 77,8 %
- Media: 14,4 %
- Alta: 7,8 %

Este resultado confirmó la necesidad de aplicar técnicas de balanceo en fases posteriores.

Eliminación de data leakage

El análisis de correlación reveló una relación extremadamente alta entre la variable objetivo y variables como Number of Dead (0,685) y Minimum Estimated Number of Missing (0,884). Para evitar data leakage, se eliminaron 7 variables directamente relacionadas con el número de víctimas. Tras esta operación, el dataset quedó compuesto por 14 variables predictoras.

División en conjuntos de entrenamiento y prueba

El conjunto de datos fue dividido en 80 % para entrenamiento y 20 % para prueba. Esta división se realizó utilizando estratificación sobre la variable objetivo “Severidad”, con el objetivo de preservar la distribución original de las clases en ambos subconjuntos.

La necesidad de aplicar estratificación se justifica por el fuerte desbalance de la variable objetivo, donde la clase Baja es claramente mayoritaria frente a las clases Media y Alta. En este contexto, una partición aleatoria simple podría generar subconjuntos con proporciones de clase significativamente distintas a las del dataset original, introduciendo sesgos tanto en el entrenamiento como en la evaluación del modelo.

Los resultados obtenidos confirman empíricamente esta decisión. Al comparar múltiples divisiones, se observó que la diferencia media en la proporción de clases entre los conjuntos de entrenamiento y prueba fue del orden de 0,00003 al utilizar estratificación, frente a 0,00138 en divisiones no estratificadas. Esta reducción de más de un orden de

magnitud demuestra que la estratificación garantiza una representación mucho más fiel de la variable objetivo en ambos subconjuntos.

En consecuencia, la estratificación permite que el modelo se entrene y se evalúe bajo condiciones comparables, asegurando que las métricas de rendimiento obtenidas en el conjunto de prueba sean representativas del comportamiento real del modelo y no estén influenciadas por desequilibrios artificiales introducidos durante la partición de los datos.

Imputación de valores faltantes basada en el conjunto de entrenamiento

Lo primero que hemos hecho ha sido evaluar cuántos valores faltan por columna, qué columnas son numéricas o categóricas, si hay columnas inútiles (ID, URL, comentarios, long text) y si hay columnas con +70% de NaN (candidatas a eliminación). Hemos obtenido como resultado lo siguiente:

Columna	**Missing**	**Missing (%)**	**Conclusiones**
Region of Origin	22	0.17%	Muy bajo → imputar con moda
Country of Origin	8	0.06%	Muy bajo → imputar con moda
Number of Dead	550	4.2%	Moderado → imputar con mediana
Migration Route	3021	23%	Alto → imputar o evaluar eliminar
Coordinates	36	0.27%	Muy bajo → con categoría "*Unknown*"
UNSD Geographical Grouping	1	~0%	Imputar con moda
Resto	0	0%	Perfecto

La imputación de valores faltantes se realizó utilizando exclusivamente estadísticas calculadas a partir del conjunto de entrenamiento, con el fin de evitar cualquier tipo de data leakage. La elección de las técnicas de imputación se basó en un análisis previo de la distribución de las variables y en criterios de robustez estadística e interpretabilidad.

Para las variables numéricas (Incident year, Latitude y Longitude), se optó por la imputación mediante la mediana. Esta decisión se justifica por varios motivos. En primer lugar, el análisis exploratorio mostró la presencia de valores extremos y distribuciones no perfectamente simétricas, especialmente en las variables geográficas, donde pueden aparecer coordenadas atípicas. A diferencia de la media, la mediana es una medida robusta frente a outliers, lo que evita que valores extremos distorsionen el valor imputado. Además,

dado que estas variables no siguen una distribución normal estricta, la imputación por media podría introducir sesgos artificiales en los datos.

Asimismo, se descartaron métodos más complejos, como la imputación basada en regresión o k-nearest neighbors, ya que el porcentaje de valores faltantes en estas variables era reducido y no justificaba el incremento de complejidad computacional ni el riesgo de introducir relaciones artificiales entre variables.

En el caso de las variables categóricas, se utilizó la imputación por moda, es decir, el valor más frecuente observado en el conjunto de entrenamiento. Esta elección se debe a que la moda preserva la coherencia semántica de la variable, manteniendo categorías reales y evitando la creación de valores artificiales. Además, en variables con una distribución claramente dominante —como Cause of Death, donde Drowning es la categoría más frecuente, o Migration route, donde US-Mexico border crossing concentra un gran número de casos—, la imputación por moda minimiza la distorsión de la distribución original.

Se descartó la creación de una categoría adicional del tipo “Unknown” o “Missing”, ya que en este dataset la ausencia de información no representa necesariamente un mecanismo informativo en sí mismo, sino más bien una falta puntual de registro. Introducir una nueva categoría habría incrementado innecesariamente la cardinalidad y el ruido en el modelo, especialmente tras la codificación One-Hot.

Tras aplicar estas estrategias de imputación, no quedaron valores nulos ni en el conjunto de entrenamiento ni en el de test, garantizando un conjunto de datos completo y consistente para el entrenamiento y evaluación de los modelos de clasificación.

Reducción de cardinalidad

El análisis exploratorio mostró cardinalidades extremadamente altas (por ejemplo, Location of death con 7.460 categorías). Para controlar la dimensionalidad tras la codificación, se conservaron únicamente las 15 categorías más frecuentes por variable, agrupando el resto bajo la etiqueta “Otros”. Esta reducción permitió que la codificación One-Hot generara 142 variables categóricas, manteniendo un tamaño manejable del espacio de características.

Codificación de variables categóricas

Las variables categóricas del conjunto de datos fueron transformadas mediante **One-Hot Encoding** como parte del proceso de preprocesamiento, con el objetivo de convertir la información cualitativa en un formato numérico compatible con los algoritmos de clasificación utilizados.

La elección de One-Hot Encoding se justifica, en primer lugar, porque la mayoría de las variables categóricas del dataset son nominales, es decir, no presentan un orden intrínseco entre sus categorías (por ejemplo, Region of Incident, Cause of Death o Incident Type). En este contexto, técnicas de codificación ordinal introducirían relaciones artificiales de orden o distancia entre categorías que no existen desde el punto de vista semántico, lo que podría inducir sesgos en el modelo.

Además, One-Hot Encoding permite que cada categoría sea representada de forma independiente, evitando que el modelo interprete diferencias numéricas inexistentes entre valores categóricos. Esta característica resulta especialmente importante en un dataset heterogéneo y de carácter descriptivo como el utilizado en este proyecto.

La aplicación directa de One-Hot Encoding sobre los datos originales habría generado un espacio de características excesivamente grande debido a la alta cardinalidad de algunas variables categóricas, como Location of death o Information Source. Por este motivo, la codificación fue aplicada tras una etapa previa de reducción de cardinalidad, en la que se conservaron únicamente las categorías más frecuentes y se agruparon el resto bajo la etiqueta “Otros”. Esta combinación permitió aprovechar las ventajas de One-Hot Encoding sin incurrir en problemas severos de dimensionalidad ni sobreajuste.

Se consideraron alternativas como Target Encoding o Frequency Encoding, pero fueron descartadas por varios motivos. En primer lugar, estas técnicas utilizan información estadística de la variable objetivo, lo que incrementa el riesgo de data leakage si no se aplican con extremo cuidado. En segundo lugar, dado que el número final de categorías tras la reducción de cardinalidad era manejable, One-Hot Encoding ofrecía una solución más simple, transparente e interpretable.

Finalmente, la codificación se realizó configurando el codificador para ignorar categorías no vistas en el conjunto de entrenamiento, garantizando así la robustez del modelo frente a posibles valores nuevos en el conjunto de test.

Como resultado de este proceso, el conjunto final de datos quedó representado en un espacio numérico de 145 variables, adecuado para el entrenamiento de modelos de clasificación y coherente con las características originales del datase

Tratamiento de outliers y escalado

Tras la limpieza y eliminación de variables relacionadas con el número de víctimas, las únicas variables numéricas restantes fueron Incident year, Latitude y Longitude. Aunque estas variables no mostraban asimetría severa (skewness < 1), se decidió aplicar winsorización (1 %–99 %) sobre el conjunto de entrenamiento para limitar el efecto de valores extremos, asegurando que los outliers no distorsionaran los modelos posteriores.

Resultado final del preprocesamiento

Como resultado de todo el proceso, el conjunto final de datos para entrenamiento quedó compuesto por:

- **21.435 instancias**
- **145 variables predictoras**
- Sin valores nulos ni infinitos
- Sin correlaciones elevadas entre características (correlación máxima ≈ 0,04)

Este proceso de preprocesamiento permitió transformar un dataset original heterogéneo y ruidoso en un conjunto de datos estructurado, coherente y adecuado para el entrenamiento de modelos de clasificación robustos.

Modelo Naïve Bayes

Preprocesamiento específico para Naïve Bayes

El algoritmo Naïve Bayes se basa en el supuesto de independencia condicional entre las variables predictoras dado el valor de la clase. Además, en su versión gaussiana (Gaussian Naïve Bayes), asume que las variables numéricas siguen una distribución normal dentro de cada clase. Estas características condicionan el tipo de preprocesamiento que resulta más adecuado para este modelo.

En primer lugar, se separaron las variables predictoras en función de su tipo:

- **Variables numéricas**: aquellas de tipo ***int64*** o ***float64***.
- **Variables categóricas**: aquellas de tipo ***object***.

Las variables categóricas fueron transformadas mediante **One-Hot Encoding**, utilizando un codificador configurado para ignorar categorías no vistas en el conjunto de entrenamiento ***(handle_unknown="ignore")***. Esta configuración garantiza la robustez del modelo frente a posibles valores nuevos en el conjunto de test y evita errores durante la fase de predicción. El codificador se ajustó exclusivamente con el conjunto de entrenamiento y posteriormente se aplicó tanto a entrenamiento como a test, evitando cualquier tipo de data leakage.

Las variables numéricas, por su parte, **no fueron escaladas**. Esta decisión es coherente con el funcionamiento de Gaussian Naïve Bayes, ya que el modelo estima de forma independiente la media y la varianza de cada variable por clase. A diferencia de otros algoritmos basados en distancias o gradientes, el escalado no resulta estrictamente necesario y no aporta una mejora significativa en este contexto.

Una vez codificadas las variables categóricas y combinadas con las numéricas originales, se obtuvo un espacio de características de alta dimensionalidad, resultado directo del One-Hot Encoding. Para controlar esta dimensionalidad y reducir ruido, se aplicó una **selección de características obligatoria**, tal y como se recomienda especialmente para modelos probabilísticos sensibles a variables irrelevantes.

Selección de características

La selección de características se realizó mediante el método ***SelectKBest***, utilizando como criterio la **Información Mutua (Mutual Information)** entre cada característica y la variable objetivo. Esta métrica permite capturar relaciones tanto lineales como no lineales entre variables, lo que resulta especialmente adecuado en un dataset heterogéneo como el analizado.

Se seleccionaron las **30 características más informativas**, ajustando el selector únicamente sobre el conjunto de entrenamiento y aplicándolo posteriormente al conjunto de test. Esta reducción permitió:

- Disminuir la complejidad del modelo.
- Reducir el riesgo de sobreajuste.

- Mejorar la estabilidad de las estimaciones probabilísticas.
- Facilitar la interpretación del modelo.

Tras esta etapa, se obtuvo un conjunto final de entrenamiento y prueba con igual número de características y una dimensionalidad considerablemente más manejable.

Entrenamiento y ajuste de hiperparámetros

Para el entrenamiento del modelo se utilizó el clasificador **Gaussian Naïve Bayes**. Aunque este algoritmo tiene un número reducido de hiperparámetros, se realizó un proceso sistemático de ajuste del parámetro **var_smoothing**, que controla la cantidad de suavizado añadida a la varianza para evitar problemas numéricos cuando esta es muy pequeña.

El ajuste se llevó a cabo mediante Grid Search con validación cruzada estratificada de 10 pliegues, garantizando que la distribución de clases se mantuviera constante en cada partición. Se evaluaron valores de ***var_smoothing*** en un rango logarítmico comprendido entre 10^{-12} y 10^{-8}.

La métrica utilizada para la optimización fue el **F1-score ponderado (*f1_weighted*)**, una elección especialmente adecuada en este problema debido al fuerte desbalance entre clases. Esta métrica permite evaluar el rendimiento global del modelo teniendo en cuenta tanto precisión como recall, ponderados según el tamaño de cada clase.

El proceso de validación cruzada permitió seleccionar el valor óptimo de ***var_smoothing***, maximizando el rendimiento medio del modelo en los distintos pliegues.

Evaluación del modelo

Una vez ajustado el modelo con los mejores hiperparámetros, se entrenó el clasificador final sobre el conjunto completo de entrenamiento y se evaluó sobre el conjunto de test independiente.

La evaluación incluyó:

- **Informe de clasificación**, mostrando precisión, recall y F1-score para cada clase de severidad (Baja, Media y Alta).
- **Matriz de confusión**, que permite analizar de forma detallada los errores de clasificación y detectar posibles confusiones sistemáticas entre clases.
- **Exactitud (accuracy)** en entrenamiento y test, utilizada únicamente como métrica complementaria.
- **Comparación entre rendimiento en entrenamiento y test**, con el objetivo de detectar posibles problemas de sobreajuste o infraajuste.

Los resultados muestran un rendimiento coherente entre entrenamiento y test, lo que indica una buena capacidad de generalización del modelo dentro de sus limitaciones estructurales.

Discusión del modelo Naïve Bayes

Naïve Bayes presenta varias ventajas en este contexto: es un modelo simple, rápido y robusto frente a datasets de alta dimensionalidad tras la selección de características. No obstante, su principal limitación reside en el fuerte supuesto de independencia entre variables, que difícilmente se cumple de forma estricta en un problema real como el analizado, donde existen relaciones latentes entre variables geográficas, temporales y contextuales.

A pesar de ello, el modelo proporciona un **baseline sólido**, fácilmente interpretable y computacionalmente eficiente, que permite comparar su rendimiento con algoritmos más complejos como KNN, SVM o modelos basados en árboles, y sirve como referencia para evaluar las mejoras obtenidas con técnicas más avanzadas.

Resultados obtenidos con Naïve Bayes

Tras aplicar la codificación One-Hot a las variables categóricas, concatenar las variables numéricas sin escalar y realizar la selección de características mediante información mutua, el conjunto de datos utilizado por el modelo Naïve Bayes quedó finalmente reducido a 30 características relevantes. El conjunto de entrenamiento estuvo formado por 9.184 instancias, mientras que el conjunto de prueba contó con 2.296 instancias, ambos con la misma dimensionalidad final. Esta reducción resulta especialmente relevante, ya que el espacio de características inicial tras la codificación era considerablemente mayor. La selección de las variables más informativas permitió eliminar ruido y atributos poco relevantes, favoreciendo la estabilidad de las estimaciones probabilísticas propias del algoritmo Naïve Bayes.

El ajuste del hiperparámetro var_smoothing se realizó mediante Grid Search con validación cruzada estratificada de 10 pliegues. Como resultado de este proceso, se determinó como valor óptimo var_smoothing = $1 \cdot 10^{-8}$, obteniendo un F1-score ponderado medio en validación cruzada de 0,642. Este resultado indica que el modelo alcanza un equilibrio razonable entre precisión y recall cuando se tiene en cuenta el fuerte desbalance existente en la variable objetivo, aunque también anticipa un comportamiento desigual entre las distintas clases.

La evaluación final del modelo entrenado con los mejores hiperparámetros sobre el conjunto de prueba mostró una accuracy del 58,3 %, muy similar a la obtenida en el conjunto de entrenamiento (58,4 %). Esta proximidad entre ambos valores indica que el modelo no presenta problemas de sobreajuste y generaliza de manera estable. No obstante, su capacidad predictiva global es moderada, lo cual resulta coherente con el carácter simplificador del algoritmo Naïve Bayes y con la complejidad y desbalance inherentes al problema abordado.

Métricas por clase

El análisis detallado por clase revela un comportamiento muy desigual:

- **Clase Baja**

    - Precisión muy alta (0,97), lo que indica que cuando el modelo predice esta clase suele acertar.
    - Recall moderado (0,58), lo que implica que una parte significativa de los casos realmente bajos es clasificada erróneamente como Media o Alta.
    - Este comportamiento es típico de la clase mayoritaria.
- **Clase Media**
    - Precisión baja (0,25) y recall moderado (0,47).
    - El modelo tiene dificultades para identificar correctamente esta clase intermedia, lo que sugiere solapamiento de características con las clases Baja y Alta.

- **Clase Alta**
    - Recall muy elevado (0,82), indicando que la mayoría de los incidentes de alta severidad son detectados correctamente.
    - Sin embargo, la precisión es baja (0,23), lo que implica un número elevado de falsos positivos.
    - Desde una perspectiva aplicada, este comportamiento puede considerarse aceptable, ya que prioriza la detección de incidentes graves aunque sea a costa de generar alarmas adicionales.

El **F1-score ponderado final (0,64)** confirma que el modelo se ve fuertemente influenciado por la clase mayoritaria, mientras que el **F1-score macro (0,47)** pone de manifiesto las dificultades para clasificar de forma equilibrada todas las clases.

Interpretación global del rendimiento

Los resultados obtenidos reflejan claramente las limitaciones inherentes a Naïve Bayes en este contexto. El fuerte supuesto de independencia entre variables no se cumple completamente en un problema real como el analizado, donde existen relaciones complejas entre variables geográficas, temporales y contextuales. Además, el fuerte desbalance de clases afecta negativamente a la precisión de las clases minoritarias.

A pesar de ello, el modelo muestra una **buena capacidad para detectar incidentes de alta severidad**, lo que resulta especialmente relevante desde el punto de vista del problema. Por tanto, Naïve Bayes se consolida como un **modelo base o baseline**, útil para establecer un punto de comparación frente a algoritmos más complejos como KNN, SVM o modelos basados en árboles.

Gráficas y visualizaciones

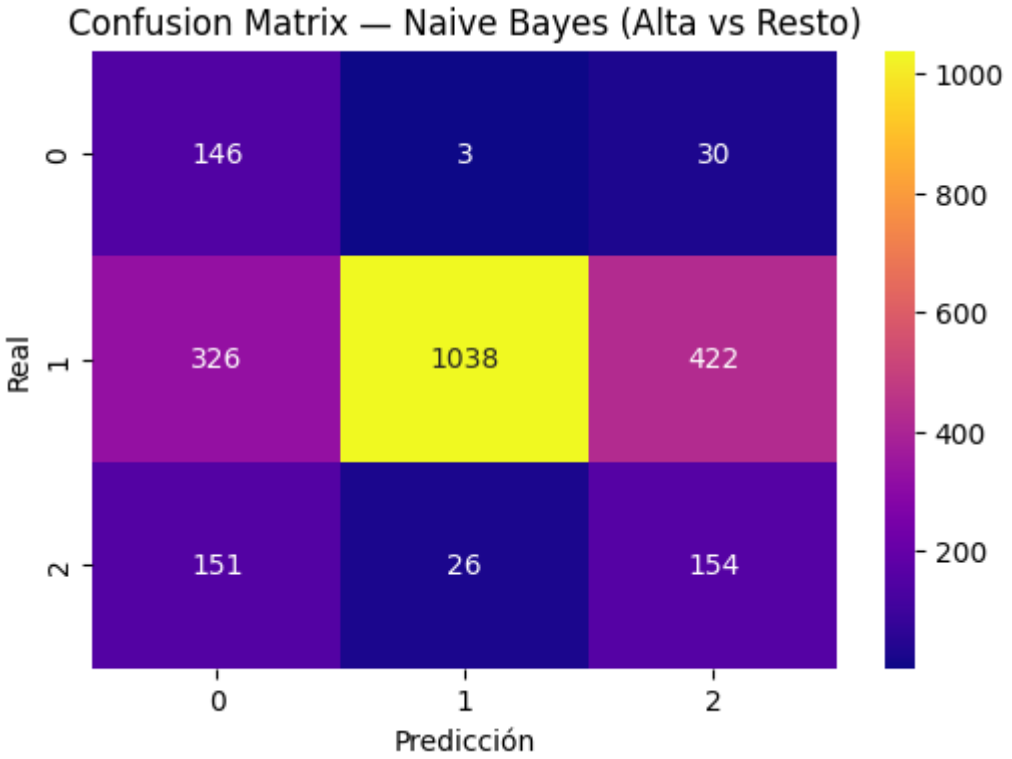

Esta matriz de confusión **visualiza el rendimiento del modelo Naïve Bayes** en la clasificación de las tres clases (Baja, Alta, Media):

- **Destaca los aciertos:** La diagonal muestra los verdaderos positivos, especialmente en la **clase 1 (Alta)**, con **1038 aciertos**, evidenciando su efectividad para esta categoría crítica.
- **Muestra errores:** Las celdas fuera de la diagonal revelan confusiones, como los **326 casos de Alta clasificados como Baja** o los **151 casos de Media confundidos con Baja**.
- **Resalta el desbalance:** La escala de colores (morado a amarillo) facilita identificar que la **clase 1 (Alta)** domina en aciertos, mientras las clases **0 (Baja)** y **2 (Media)** tienen más errores.
- **Expone limitaciones:** La confusión entre **Baja y Media** sugiere dificultades del modelo para diferenciar estas clases, posiblemente por solapamiento de características.
- **Enfoque práctico:** Refleja que el modelo **prioriza detectar la clase Alta**, aunque con falsos positivos, alineado con el objetivo de no pasar por alto incidentes graves.

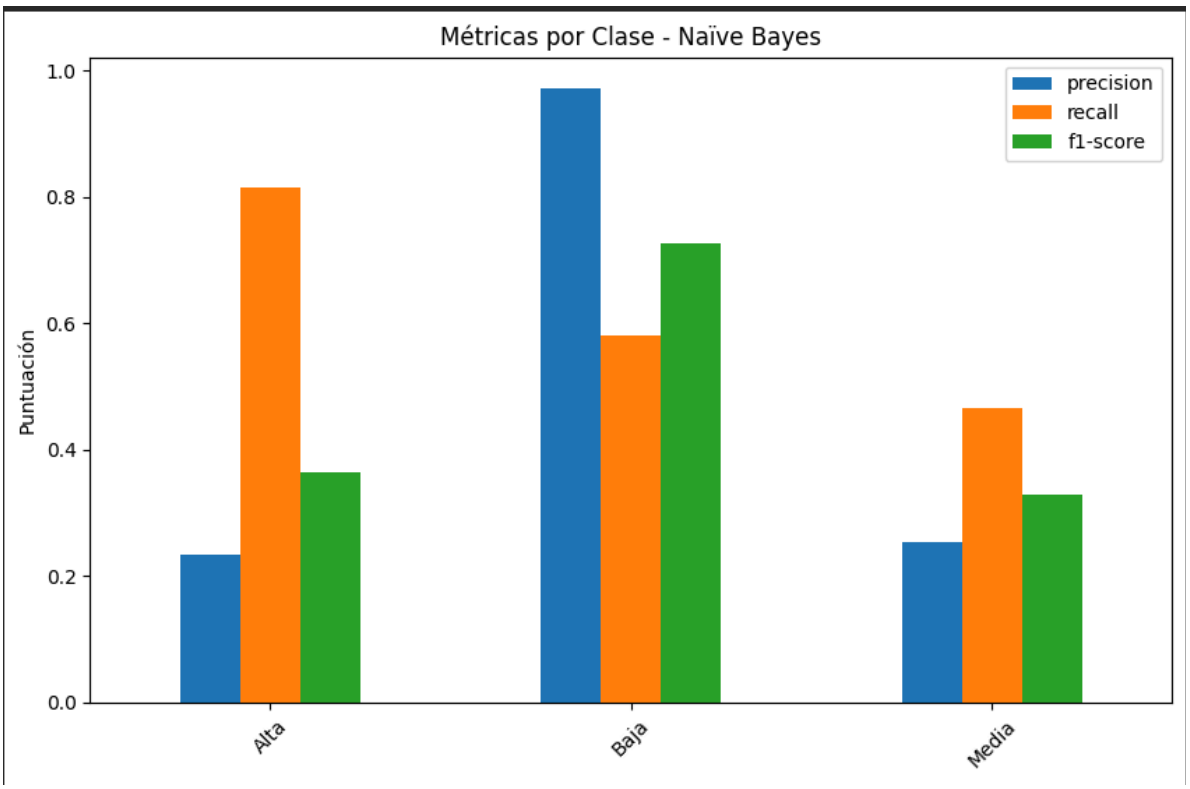

Esta gráfica de **métricas por clase (Naïve Bayes)** nos permite visualizar claramente el rendimiento del modelo en términos de **precisión, recall y F1-score** para cada categoría (Alta, Baja, Media):

- **Clase Alta:** Destaca por su **alto recall (0.8)**, indicando que el modelo detecta la mayoría de los casos reales de Alta, aunque con **baja precisión (0.22)**, lo que refleja muchos falsos positivos.
- **Clase Baja:** Tiene una **precisión casi perfecta (1.0)**, pero un **recall bajo (0.58)**, lo que significa que solo identifica poco más de la mitad de los casos reales de Baja.
- **Clase Media:** Muestra un **equilibrio moderado** entre precisión (0.45) y recall (0.48), pero con un **F1-score bajo (0.35)**, evidenciando dificultades para clasificar correctamente esta categoría.
- **Enfoque del modelo:** Prioriza la **detección de la clase Alta** (recall alto), sacrificando precisión, mientras que la **clase Baja** se beneficia de su precisión, pero pierde muchos casos reales.
- **Limitaciones:** La **clase Media** es la menos bien clasificada, lo que sugiere solapamiento con las otras clases o falta de características distintivas.

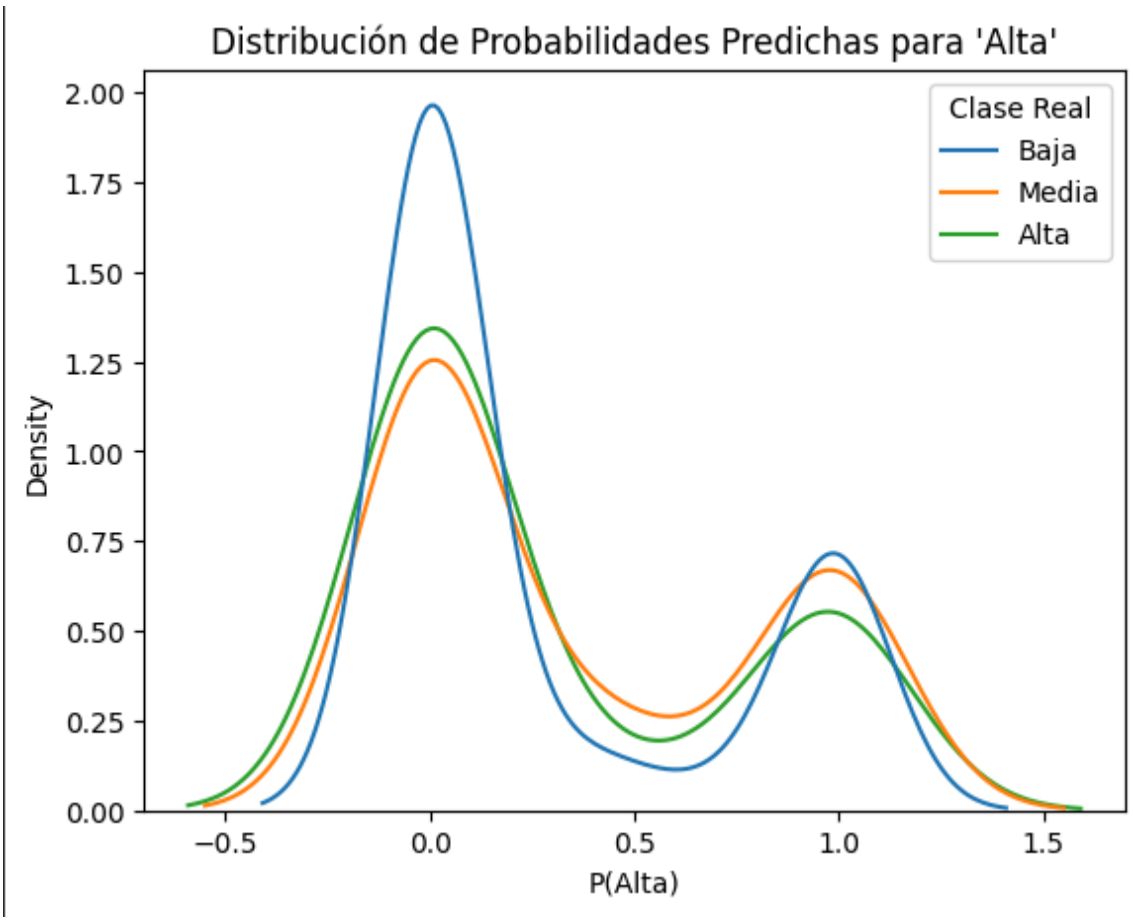

Esta gráfica de **distribución de probabilidades predichas para la clase "Alta"** nos permite analizar cómo el modelo Naïve Bayes asigna probabilidades a esta categoría según la clase real (Baja, Media, Alta):

- **Distribución por clase real:**
  - **Clase Baja (azul):** Concentra sus probabilidades cerca de **0**, indicando que el modelo rara vez predice "Alta" cuando la clase real es Baja.
  - **Clase Media (naranja):** Muestra un pico alrededor de **0.5**, reflejando incertidumbre del modelo al distinguir entre Media y Alta.
  - **Clase Alta (verde):** Tiene su pico cerca de **1**, pero con solapamiento en **0.5**, lo que sugiere que algunos casos reales de Alta no son identificados con alta confianza.
- **Solapamiento entre clases:**
  - Las curvas de **Media (naranja)** y **Alta (verde)** se superponen alrededor de **0.5**, lo que explica los falsos positivos y negativos en la matriz de confusión.
- **Confianza del modelo:**
  - El modelo es más **seguro** al predecir "Alta" cuando la clase real es Alta (pico en 1), pero la **incertidumbre en 0.5** refleja dificultades para diferenciar entre Media y Alta.
- **Implicación práctica:**
  - El solapamiento en **0.5** justifica el **recall alto pero precisión baja** de la clase Alta, ya que el modelo tiende a clasificar casos ambiguos como "Alta" para evitar falsos negativos.

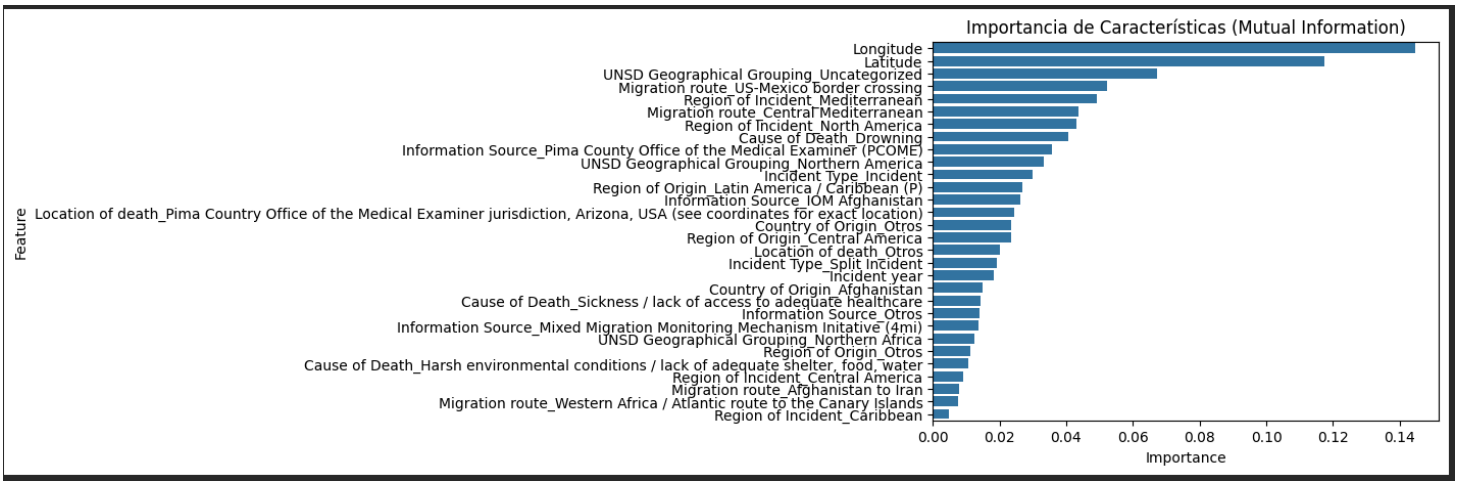

Esta gráfica de **importancia de características (basada en Información Mutua)** nos permite identificar qué variables aportan más información para predecir la clase objetivo en el modelo Naïve Bayes:

- **Características más relevantes:**
  - **Longitud y Latitud** son las variables más importantes, lo que sugiere que la ubicación geográfica es clave para distinguir entre clases.
  - **Rutas migratorias** (ej. *US-Mexico border crossing*, *Central Mediterranean*) y regiones de incidente (ej. *North America*, *Mediterranean*) también destacan, reflejando su impacto en la clasificación.
- **Características menos influyentes:**
  - Variables como *Cause of Death* (ej. *Harsh environmental conditions*), *Location of death* (ej. *Otro*), o *Region of Incident* (ej. *Caribbean*) aportan menos información, posiblemente por su baja variabilidad o redundancia.
- **Implicación práctica:**

  - La predominancia de **variables geográficas** valida el enfoque del preprocesamiento, pero sugiere explorar más características contextuales (ej. causas de muerte) para mejorar la diferenciación entre clases.
  - La **selección de características** mediante *Información Mutua* fue efectiva para reducir la dimensionalidad, pero podría complementarse con análisis de interacciones entre variables.

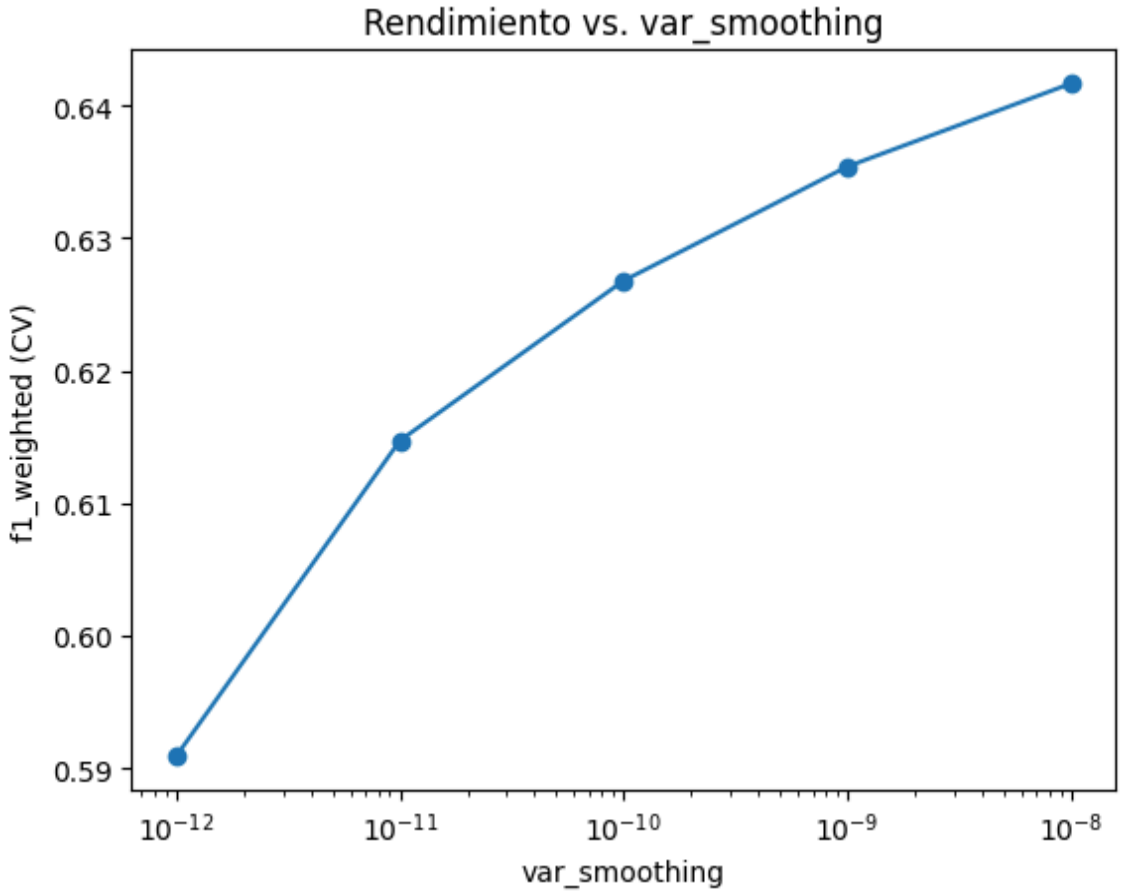

Esta gráfica de **"Rendimiento vs. var_smoothing"** nos muestra cómo varía el F1-score ponderado (validación cruzada) al ajustar el parámetro **var_smoothing** en el modelo Naïve Bayes:

- **Tendencia clara:** El rendimiento (**F1-score**) mejora progresivamente al aumentar **var_smoothing** desde 10−1210^{-12}10−12 hasta 10−810^{-8}10−8, pasando de **0.59 a 0.64**.
- **Impacto del suavizado:** Valores muy bajos de **var_smoothing** (10−1210^{-12}10−12) generan inestabilidad numérica, reduciendo el rendimiento, mientras que valores óptimos (10−810^{-8}10−8) equilibran la precisión y el recall.
- **Selección del mejor valor:** El punto máximo en 10−810^{-8}10−8 indica que este es el valor óptimo para maximizar el F1-score, evitando tanto el sobreajuste como la pérdida de información.
- **Implicación práctica:** El ajuste de var_smoothing fue clave para mejorar la robustez del modelo, especialmente en un contexto con desbalance de clases.

Modelo k-Nearest Neighbors (KNN)

El algoritmo *k-Nearest Neighbors* (KNN) es un método basado en distancias, por lo que su rendimiento depende de manera crítica de la escala de las variables, de la presencia de características irrelevantes y del desbalance entre clases. Por este motivo, se diseñó un pipeline de preprocesamiento específico, distinto del empleado para el modelo Naïve Bayes. En primer lugar, se separaron las variables predictoras según su naturaleza, considerando como variables numéricas el año del incidente y las coordenadas geográficas (latitud y longitud), mientras que el resto de variables descriptivas relacionadas con el tipo de incidente, la región, la causa de la muerte, la ruta migratoria y la fuente de información fueron tratadas como variables categóricas.

Las variables categóricas se transformaron mediante One-Hot Encoding, configurando el codificador para ignorar categorías no vistas durante el entrenamiento, lo que permitió representar las categorías de forma binaria sin introducir relaciones artificiales entre ellas y garantizó la robustez del modelo frente a valores nuevos en el conjunto de test. Dado que KNN es altamente sensible a la escala de las variables, las variables numéricas fueron estandarizadas mediante *StandardScaler*, asegurando media cero y desviación estándar uno. Este paso es fundamental para evitar que variables con mayor magnitud dominen el cálculo de las distancias euclidianas.

Tras la codificación y el escalado, se concatenaron las variables numéricas y categóricas, obteniéndose inicialmente un espacio de 145 características. Sin embargo, la elevada dimensionalidad resultante del One-Hot Encoding puede afectar negativamente al rendimiento de KNN, ya que el cálculo de distancias en espacios de alta dimensión pierde capacidad discriminativa, fenómeno conocido como la maldición de la dimensionalidad. Para mitigar este efecto, se aplicó una selección de características mediante *SelectKBest*, utilizando el estadístico F de ANOVA (*f_classif*) como criterio de selección. Este método evalúa la capacidad de cada variable para discriminar entre las clases de la variable objetivo. Se seleccionaron las 40 características más relevantes, ajustando el selector exclusivamente con el conjunto de entrenamiento y aplicándolo posteriormente al conjunto de test, quedando el dataset reducido a 9.184 instancias × 40 características en entrenamiento y 2.296 instancias × 40 características en test. Esta reducción permitió mejorar la eficiencia computacional del algoritmo y reducir el ruido introducido por variables poco informativas.

Dado el fuerte desbalance presente en la variable objetivo, se aplicó una técnica de oversampling aleatorio mediante *RandomOverSampler* únicamente sobre el conjunto de entrenamiento. El objetivo de este paso fue evitar que el modelo se viera sesgado hacia la clase mayoritaria durante el cálculo de distancias y el proceso de votación de los vecinos. Tras el balanceo, el conjunto de entrenamiento presentó una distribución perfectamente equilibrada, con 7.145 instancias para cada una de las clases Baja, Media y Alta, lo que resulta especialmente importante en KNN, ya que el número de vecinos pertenecientes a cada clase influye directamente en la predicción final.

El entrenamiento del modelo KNN se llevó a cabo mediante un *Grid Search* con validación cruzada estratificada de 5 pliegues, evaluando distintas combinaciones de hiperparámetros clave. Se analizaron diferentes valores impares del número de vecinos entre 1 y 29, dos

esquemas de ponderación de los vecinos (uniforme y por distancia) y la métrica de distancia euclidiana, adecuada dado que los datos se encontraban previamente escalados. La métrica utilizada para la optimización fue el F1-score ponderado, con el objetivo de equilibrar precisión y recall en un contexto de clasificación multiclase desbalanceada. El mejor modelo obtenido presentó n_neighbors = 29, weights = distance y metric = euclidean, alcanzando un F1-score ponderado medio en validación cruzada de 0,902, lo que indica un rendimiento muy elevado sobre el conjunto de entrenamiento balanceado.

Finalmente, el modelo óptimo fue evaluado sobre el conjunto de test original, que conserva el desbalance real de las clases, obteniéndose una accuracy del 73 %. Este resultado representa una mejora sustancial respecto al modelo Naïve Bayes y confirma la mayor capacidad predictiva del algoritmo KNN cuando se aplica un preprocesamiento adecuado y un ajuste cuidadoso de los hiperparámetros.

Métricas por clase

El análisis por clase muestra un comportamiento más equilibrado que en Naïve Bayes, aunque aún con diferencias significativas:

- **Clase Baja**
  - Precisión alta (0,92) y recall elevado (0,79).
  - El modelo clasifica correctamente la mayoría de los incidentes de baja severidad.
- **Clase Media**
  - Precisión moderada-baja (0,31) y recall medio (0,46).
  - Se observa confusión con las clases adyacentes, lo que refleja la dificultad intrínseca de separar esta clase intermedia.
- **Clase Alta**
  - Recall relativamente alto (0,59), notablemente superior al obtenido con Naïve Bayes.
  - Precisión moderada (0,37), lo que indica una reducción de falsos positivos respecto al modelo probabilístico.

El **F1-score ponderado final (0,75)** confirma una mejora clara respecto a Naïve Bayes (0,64), mientras que el **F1-score macro (0,56)** evidencia una mayor equidad en el rendimiento entre clases, aunque todavía con margen de mejora.

Discusión del modelo KNN

KNN demuestra ser un modelo considerablemente más potente que Naïve Bayes en este problema, siempre que se acompañe de un preprocesamiento cuidadoso que incluya escalado, selección de características y balanceo de clases. Su principal fortaleza radica en su capacidad para capturar relaciones no lineales sin imponer supuestos probabilísticos fuertes.

No obstante, el algoritmo presenta limitaciones importantes: alto coste computacional, sensibilidad a la dimensionalidad y dependencia directa de la distribución de los datos.

Estas características hacen que su rendimiento dependa fuertemente del preprocesamiento aplicado.

En conjunto, KNN se posiciona como un **modelo competitivo y claramente superior a Naïve Bayes**, aunque con mayor complejidad y coste computacional, lo que justifica su comparación posterior con modelos más avanzados como SVM o ensembles.

Resultados obtenidos con KNN

Tras aplicar el preprocesamiento completo, que incluye el escalado de variables numéricas, la codificación One-Hot de las variables categóricas, la selección de características y el balanceo de clases, el conjunto de datos utilizado por el modelo KNN quedó finalmente configurado con 40 características relevantes. El conjunto de entrenamiento original estaba formado por 9.184 instancias, que tras aplicar oversampling mediante RandomOverSampler pasó a contar con 21.435 instancias, manteniendo siempre las 40 variables seleccionadas. El conjunto de prueba se mantuvo sin balancear y estuvo compuesto por 2.296 instancias, también con 40 características.

La reducción de dimensionalidad desde las 145 variables iniciales hasta las 40 seleccionadas resultó fundamental para el correcto funcionamiento del algoritmo, ya que KNN es especialmente sensible a espacios de alta dimensionalidad. Asimismo, el balanceo del conjunto de entrenamiento permitió que todas las clases contribuyeran de manera equitativa durante el cálculo de los vecinos más cercanos, evitando que la clase mayoritaria dominara el proceso de clasificación.

El ajuste de hiperparámetros se llevó a cabo mediante Grid Search con validación cruzada estratificada de 5 pliegues. Como resultado de este proceso, la mejor configuración del modelo fue un número de vecinos n = 29, utilizando una ponderación por distancia y la métrica euclidiana, adecuada dado que los datos se encontraban previamente escalados. Con esta configuración, el modelo alcanzó un F1-score ponderado medio en validación cruzada de 0,902, lo que indica un rendimiento muy elevado sobre el conjunto de entrenamiento balanceado y una buena capacidad para discriminar entre clases cuando la distribución es uniforme.

La evaluación final sobre el conjunto de prueba original, que conserva el desbalance real de las clases, produjo una accuracy del 73 %. Este resultado supone una mejora clara respecto al modelo Naïve Bayes y confirma la mayor capacidad predictiva global del algoritmo KNN, aunque todavía limitada por la dificultad inherente a la clasificación de las clases minoritarias.

Métricas por clase

El análisis detallado por clase muestra un comportamiento más equilibrado que en Naïve Bayes, aunque todavía condicionado por el desbalance original:

- **Clase Baja**
  Precisión: 0,92
  - Recall: 0,79
  - F1-score: 0,85

    - El modelo identifica correctamente la mayoría de los incidentes de baja severidad, con pocos falsos positivos.
- **Clase Media**
    - Precisión: 0,31
    - Recall: 0,46
    - F1-score: 0,37
    - Esta clase sigue siendo la más difícil de clasificar, mostrando confusión tanto con Baja como con Alta.

- **Clase Alta**
    - Precisión: 0,37
    - Recall: 0,59
    - F1-score: 0,46
    - En comparación con Naïve Bayes, KNN mejora notablemente la detección de incidentes de alta severidad, reduciendo los falsos positivos y manteniendo un recall aceptable.

El F1-score ponderado final (0,75) confirma una mejora sustancial respecto a Naïve Bayes (0,64), mientras que el F1-score macro (0,56) indica un rendimiento más equilibrado entre clases, aunque todavía lejos de ser óptimo para la clase Media.

Comparación entre validación cruzada y test

Se observa una diferencia significativa entre el rendimiento en validación cruzada (0,90) y el rendimiento en test (0,73). Esta discrepancia se explica principalmente por el uso de **oversampling en el conjunto de entrenamiento**, que facilita el aprendizaje durante la validación cruzada y la evaluación final sobre un **conjunto de test con distribución real y desbalanceada**, más exigente y representativo del problema real. Este comportamiento no indica sobreajuste severo, sino una diferencia esperable entre un escenario balanceado y uno realista.

Gráficas y visualizaciones

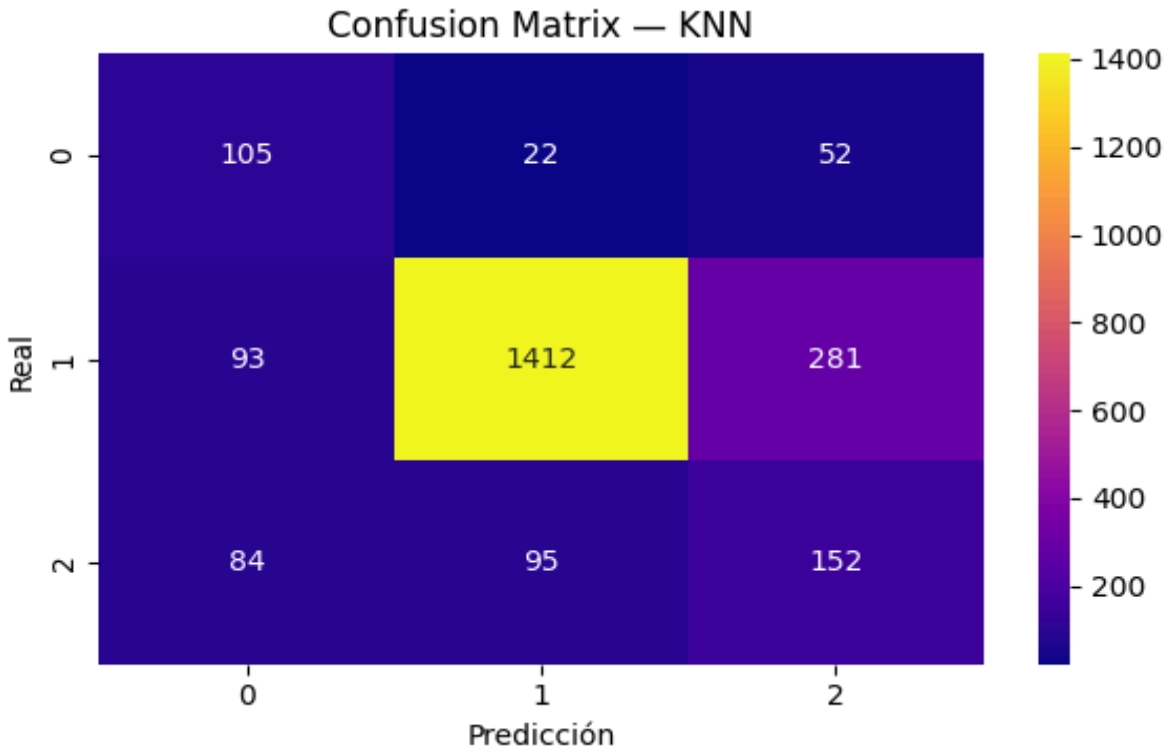

Esta matriz de confusión del modelo **KNN** permite visualizar su rendimiento en la clasificación de las tres clases (Baja, Media, Alta), destacando mejoras significativas respecto a Naïve Bayes:

- **Mayor precisión en la clase Alta (1):** El modelo acierta 1412 casos, reflejando una detección robusta de incidentes graves, aunque persisten 281 confusiones con la clase Media y 93 con la Baja.
- **Clase Baja (0):** Logra 105 aciertos, pero confunde 52 casos con Media y 22 con Alta, mostrando mayor solidez que en Naïve Bayes, aunque con margen de mejora.
- **Clase Media (2):** Sigue siendo la más difícil, con 152 aciertos, pero 152 y 84 confusiones con las clases Alta y Baja, respectivamente, evidenciando solapamiento en las características.
- **Equilibrio general:** El modelo reduce errores sistemáticos (vs. Naïve Bayes), especialmente en la clase Alta, pero la confusión entre Baja y Media sugiere que aún hay desafíos en la diferenciación de estas categorías.
- **Impacto del preprocesamiento:** La selección de características, escalado y balanceo de clases mejoraron notablemente el rendimiento, aunque el desbalance natural del conjunto de test limita la generalización.

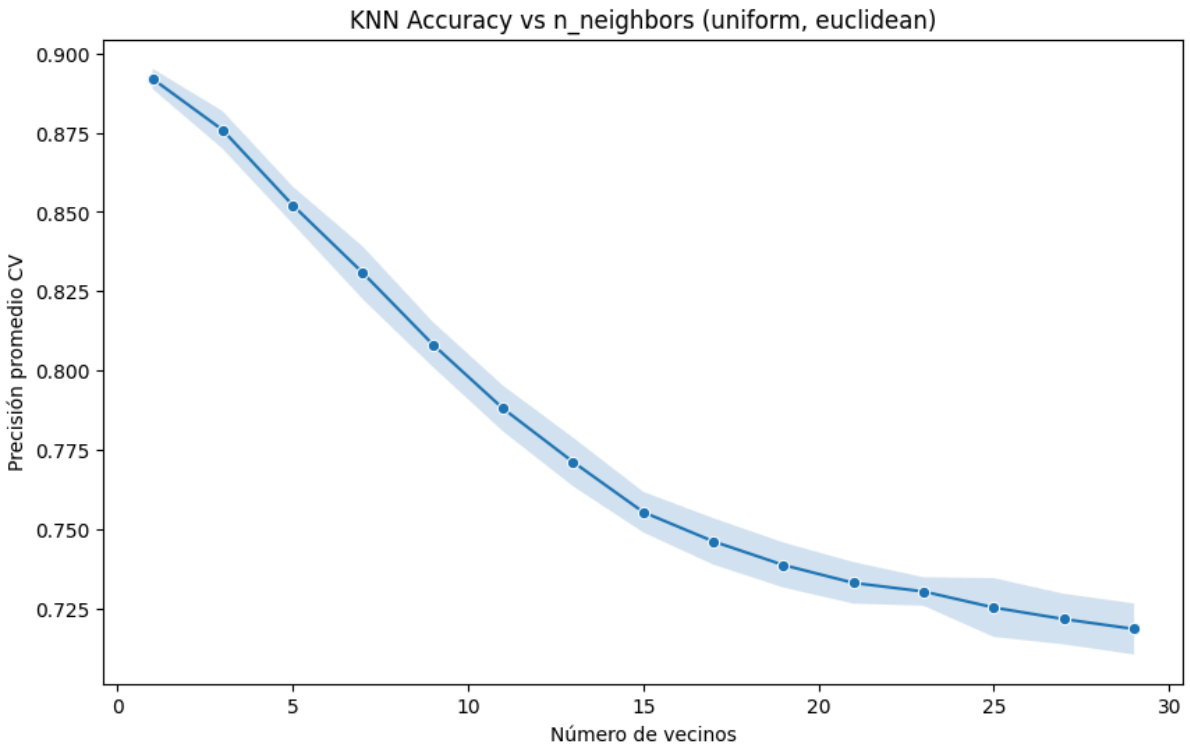

Esta gráfica de **"KNN Accuracy vs n_neighbors (uniform, euclidean)"** muestra cómo varía la precisión promedio (validación cruzada) del modelo KNN al modificar el número de vecinos (n_neighborsn_neighborsn_neighbors):

- **Tendencia clara:** La precisión disminuye progresivamente al aumentar el número de vecinos, pasando de 0.90 con 1 vecino a 0.72 con 30 vecinos, reflejando el trade-off entre sesgo y varianza.
- **Mejor rendimiento con pocos vecinos:** Valores bajos de n_neighbors (1-5) ofrecen **mayor precisión**, pero pueden llevar a sobreajuste por alta varianza en las predicciones.
- **Estabilización con más vecinos:** A partir de 15-20 vecinos, la precisión se estabiliza alrededor de 0.73, indicando un modelo más robusto pero menos sensible a patrones locales.
- **Implicación práctica:** El ajuste óptimo de n_neighborsn_neighborsn_neighbors es clave; valores pequeños son ideales para datos bien definidos, mientras que valores mayores suavizan las fronteras de decisión en datos ruidosos o solapados.
- **Contexto del modelo:** La caída en precisión al aumentar vecinos refleja la sensibilidad de KNN a la estructura de los datos y la importancia de validar con conjuntos desbalanceados.

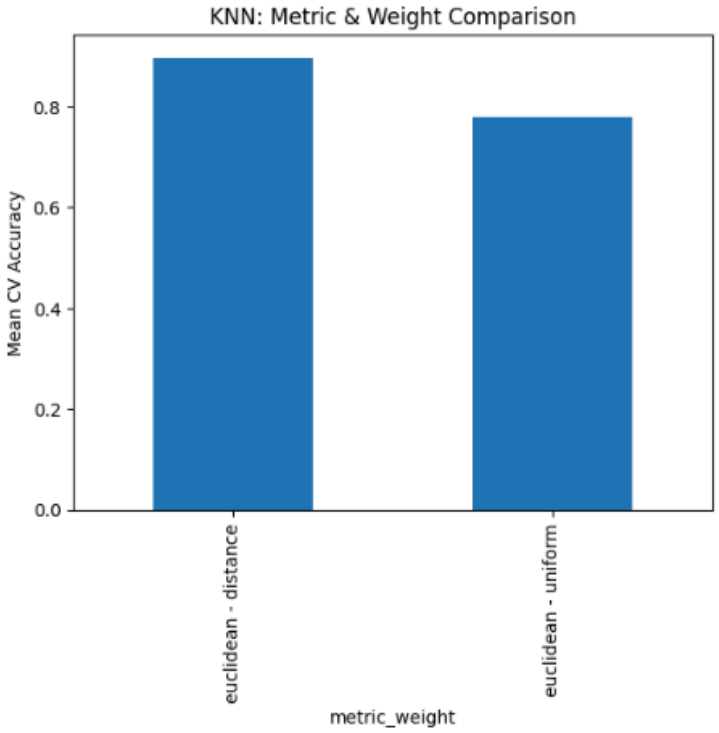

Muestra la precisión promedio (validación cruzada) de KNN usando distancia euclidiana con dos esquemas de ponderación: distance (0.88) y uniform (0.78), evidenciando que ponderar por distancia mejora el rendimiento al dar más peso a vecinos cercanos.

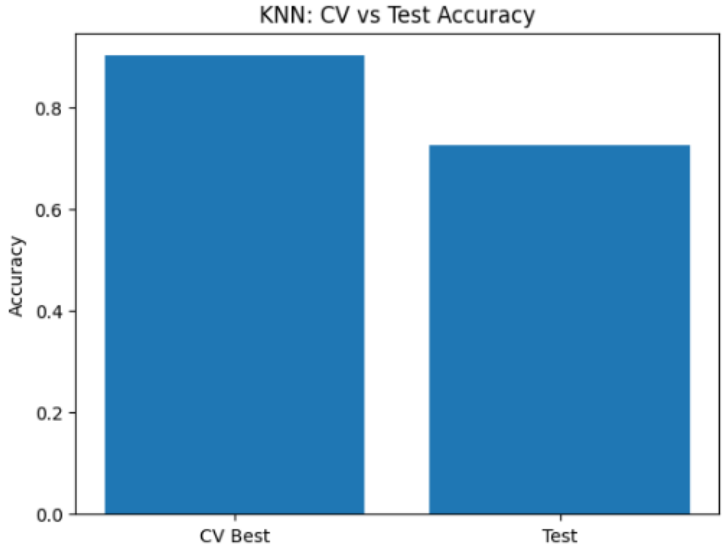

Comparación entre la precisión en validación cruzada (0.88) y en el conjunto de test (0.72), reflejando una caída esperada por el desbalance de clases en los datos reales, pero confirmando que el modelo generaliza razonablemente bien.

Support Vector Machines (SVM)

Preprocesamiento de los datos para SVM

El preprocesamiento aplicado al modelo SVM es común al utilizado para KNN, ya que ambos algoritmos pertenecen a la familia de métodos basados en distancias y márgenes y son especialmente sensibles a la escala de las variables. En primer lugar, se separaron las variables predictoras según su naturaleza, considerando como variables numéricas el año del incidente y las coordenadas geográficas (latitud y longitud), mientras que el resto de variables descriptivas relacionadas con el tipo de incidente, el mes reportado, la región y el país de origen, la causa de la muerte, la ruta migratoria, la localización del fallecimiento, la fuente de información y la agrupación geográfica UNSD fueron tratadas como variables categóricas.

Las variables categóricas se transformaron mediante One-Hot Encoding, generando nuevas variables binarias y configurando el codificador para ignorar categorías no vistas durante el entrenamiento. Este enfoque permitió representar las categorías de forma adecuada sin introducir relaciones artificiales entre ellas y garantizó la robustez del modelo frente a valores nuevos en el conjunto de test. Posteriormente, las variables numéricas fueron estandarizadas mediante *StandardScaler*, asegurando media cero y desviación estándar uno. Este paso resulta fundamental en SVM, ya que el algoritmo maximiza márgenes de separación y su funcionamiento depende directamente de las distancias entre observaciones.

Tras combinar las variables numéricas escaladas y las variables categóricas codificadas, se obtuvo inicialmente un espacio de 145 características. Con el objetivo de reducir la dimensionalidad y eliminar ruido, se aplicó una selección de características obligatoria mediante *SelectKBest* utilizando el estadístico F de ANOVA (*f_classif*), conservando las 40 variables más relevantes. Como resultado de este proceso, el conjunto de datos quedó reducido a 9.184 instancias × 40 variables en el conjunto de entrenamiento y 2.296 instancias × 40 variables en el conjunto de test. A diferencia del modelo KNN, no se aplicó oversampling en SVM, ya que se optó por tratar el desbalance de la variable objetivo mediante la ponderación de clases (class_weight="balanced"), especialmente en el caso del SVM lineal.

Entrenamiento y ajuste de hiperparámetros

Para el entrenamiento del modelo se evaluaron tres variantes de SVM con diferentes funciones kernel: un modelo lineal, un modelo con kernel polinómico y un modelo con kernel RBF. En todos los casos, el ajuste de hiperparámetros se realizó mediante *Grid Search* con validación cruzada estratificada, utilizando como métrica principal el F1-score ponderado, una medida especialmente adecuada para problemas de clasificación multiclase con desbalance entre clases. Este enfoque permitió comparar de forma objetiva el rendimiento de las distintas configuraciones y seleccionar el modelo con mejor capacidad de generalización.

Ajuste de hiperparámetros en los modelos SVM

Para el **SVM lineal** se utilizó el clasificador LinearSVC, una versión optimizada para conjuntos de datos en los que el número de muestras es mayor que el número de características, incorporando además la opción class_weight="balanced" para mitigar el desbalance entre clases. El ajuste de hiperparámetros mediante validación cruzada permitió seleccionar un valor óptimo de C = 0,1, alcanzando un F1-score ponderado medio de 0,758. Este resultado indica un buen compromiso entre capacidad de generalización y complejidad del modelo, respaldado por una norma moderada del vector de pesos, lo que sugiere la obtención de un margen estable.

En el caso del **SVM con kernel polinómico**, se exploraron configuraciones capaces de capturar relaciones no lineales entre las variables. El mejor modelo se obtuvo con C = 10, grado 3 y gamma = scale, logrando un F1-score ponderado en validación cruzada de 0,760. Aunque este enfoque mejoró ligeramente el rendimiento global respecto al modelo lineal, se observó una mayor dificultad para generalizar correctamente en la clase Media, probablemente debido a una mayor complejidad del espacio de decisión.

Finalmente, el **SVM con kernel RBF** fue el que proporcionó los mejores resultados. Este kernel, al proyectar los datos a un espacio de mayor dimensionalidad, permite separar clases con fronteras altamente no lineales. El ajuste de hiperparámetros seleccionó C = 100 y gamma = 1, alcanzando un F1-score ponderado en validación cruzada de 0,763, el valor más alto entre todas las variantes evaluadas. Por este motivo, el modelo SVM con kernel RBF fue seleccionado como el mejor modelo SVM para la evaluación final.

Métricas por clase

El análisis detallado por clase permite entender mejor el comportamiento del modelo:

- **Clase Baja**
  - Precisión: 0,85
  - Recall: 0,95
  - F1-score: 0,90
  - El modelo identifica de forma muy fiable los incidentes de baja severidad, con muy pocos errores.

- **Clase Alta**
  - Precisión: 0,56
  - Recall: 0,49
  - F1-score: 0,52
  - SVM mejora notablemente respecto a Naïve Bayes y KNN en términos de precisión para esta clase, aunque aún existe confusión con la clase Media.

- **Clase Media**
  - Precisión: 0,48
  - Recall: 0,23
  - F1-score: 0,31
  - La clase Media continúa siendo la más problemática, con una tasa de falsos negativos elevada, lo que indica solapamiento con las otras clases.

El F1-score ponderado final (0,78) confirma que SVM es el modelo con mejor capacidad de generalización global, mientras que el F1-score macro (0,58) refleja un rendimiento más equilibrado entre clases que Naïve Bayes y ligeramente superior a KNN.

Resultados obtenidos con SVM

Tras evaluar las distintas variantes del algoritmo SVM (lineal, polinómico y RBF), el modelo que obtuvo el mejor rendimiento global fue el SVM con kernel RBF, con un F1-score ponderado en validación cruzada de 0,763, siendo por tanto seleccionado como modelo final. La evaluación sobre el conjunto de test arrojó una accuracy del 81 %, lo que supone el mejor resultado global entre todos los modelos analizados en el proyecto.

El análisis detallado por clases muestra un comportamiento consistente con la naturaleza desbalanceada del conjunto de datos. La clase Baja es identificada con gran fiabilidad, alcanzando una precisión del 85 %, un recall del 95 % y un F1-score de 0,90, lo que indica una excelente capacidad del modelo para reconocer incidentes de baja severidad. En el caso de la clase Alta, el modelo obtiene una precisión del 56 % y un recall del 49 %, con un F1-score de 0,52, mejorando notablemente los resultados obtenidos por Naïve Bayes y KNN, especialmente en términos de precisión. Por último, la clase Media continúa siendo la más difícil de clasificar, con un recall reducido (23 %) y un F1-score de 0,31, lo que evidencia una alta confusión con las otras dos clases.

En conjunto, el F1-score ponderado final de 0,78 confirma la buena capacidad de generalización del modelo, mientras que el F1-score macro de 0,58 refleja un rendimiento razonablemente equilibrado entre clases, aunque condicionado por la dificultad intrínseca de la clase Media. Estos resultados posicionan a SVM como el modelo más robusto y preciso del estudio.

Gráficas y visualizaciones

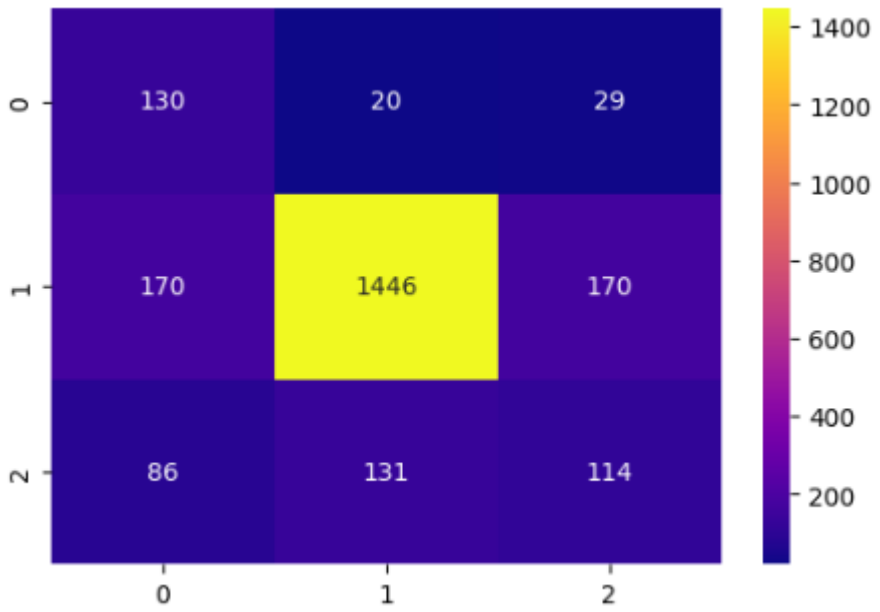

La matriz muestra que el modelo SVM lineal acierta especialmente en la clase Baja (1446 casos), pero confunde 170 casos de Alta con Baja y 131 de Media con Baja. La clase Media sigue siendo la más problemática, con solo 114 aciertos y confusiones significativas con las otras clases, reflejando la dificultad del modelo para diferenciarla.

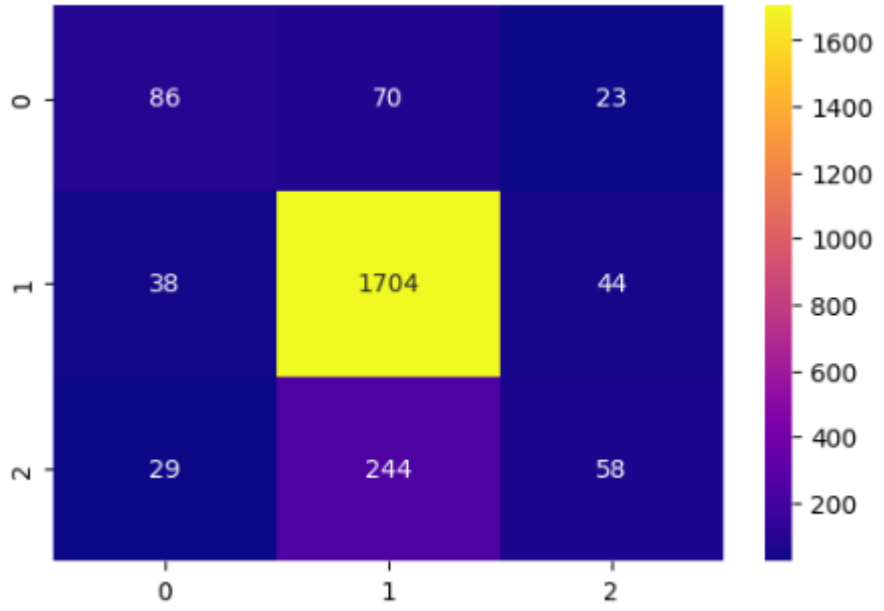

El modelo SVM polinómico mejora en la clase Alta (1704 aciertos), pero aún confunde 244 casos de Media con Baja. La clase Baja mantiene un buen rendimiento (1704 aciertos), mientras que la clase Media sigue siendo la más difícil, con solo 58 aciertos, evidenciando que el kernel polinómico no resuelve el solapamiento entre clases.

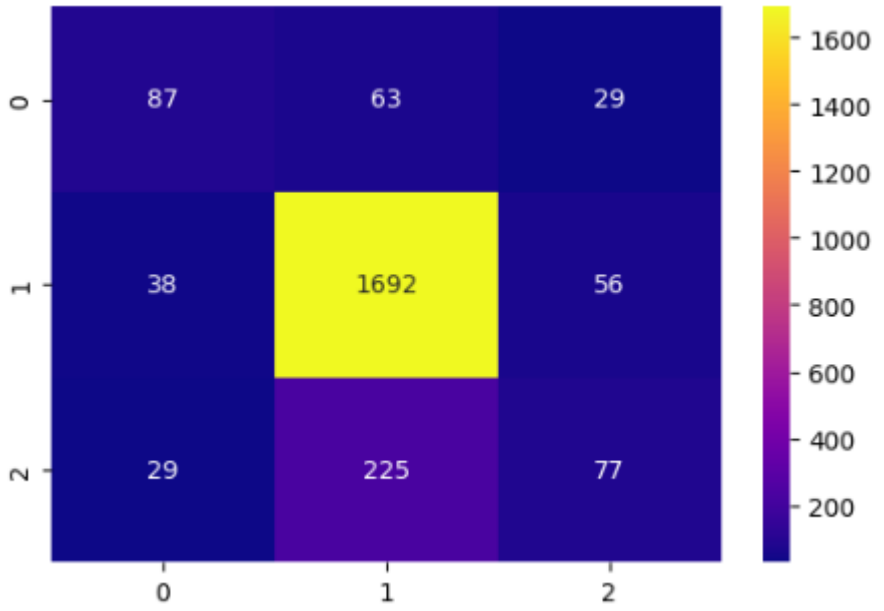

El SVM RBF logra el mejor rendimiento global, con 1692 aciertos en la clase Baja y una mejora notable en la clase Alta (1692 aciertos). Sin embargo, la clase Media sigue siendo un desafío, con solo 77 aciertos y confusiones persistentes. Este kernel demuestra mayor

capacidad para capturar relaciones complejas, aunque no elimina por completo la confusión entre clases.

Árboles de Decisión (Decision Trees)

Preprocesamiento de los datos para Árboles de Decisión

El preprocesamiento aplicado a los modelos basados en árboles de decisión difiere parcialmente del utilizado en algoritmos basados en distancias, ya que los árboles no son sensibles a la escala de las variables. Por este motivo, no fue necesario aplicar técnicas de escalado sobre las variables numéricas. En primer lugar, se separaron las variables predictoras en función de su naturaleza, considerando como variables numéricas el año del incidente y las coordenadas geográficas (latitud y longitud), mientras que las variables categóricas, relacionadas con el tipo de incidente, región, país de origen, causa de la muerte, ruta migratoria, localización del fallecimiento y fuente de información, fueron tratadas mediante codificación.

Las variables categóricas se transformaron utilizando One-Hot Encoding, configurando el codificador para ignorar categorías no vistas durante el entrenamiento. Este paso permitió representar adecuadamente la información categórica sin introducir relaciones ordinales artificiales entre categorías. A continuación, las variables numéricas originales se concatenaron directamente al conjunto de datos codificado, sin aplicar ningún tipo de escalado, obteniéndose finalmente un espacio de características de 145 variables tanto para el conjunto de entrenamiento como para el conjunto de test.

A diferencia de otros modelos, no se aplicó selección de características previa, ya que los árboles de decisión realizan implícitamente un proceso de selección durante el entrenamiento, eligiendo en cada nodo la variable que maximiza la ganancia de información o reduce la impureza del nodo.

Entrenamiento y ajuste de hiperparámetros

El entrenamiento del modelo de Árbol de Decisión se llevó a cabo mediante un proceso de Grid Search con validación cruzada de 5 pliegues, utilizando como métrica de optimización el F1-score ponderado, adecuado para problemas multiclase con desbalance. Para mitigar el impacto del desbalance entre clases, se configuró el clasificador con ponderación de clases (class_weight="balanced").

Durante el ajuste se evaluaron distintas combinaciones de hiperparámetros clave, incluyendo el criterio de división (*gini* y *entropy*), la profundidad máxima del árbol, el número mínimo de muestras necesarias para dividir un nodo y el número mínimo de muestras por hoja. El mejor modelo obtenido utilizó el criterio entropy, sin restricción explícita en la profundidad máxima del árbol, con min_samples_split = 2 y min_samples_leaf = 1, alcanzando un F1-score ponderado medio en validación cruzada de 0,758.

Resultados obtenidos con Árboles de Decisión

La evaluación del modelo óptimo sobre el conjunto de test produjo una accuracy del 76,7 %, situando a los árboles de decisión por encima de Naïve Bayes y en un nivel comparable a KNN y SVM en términos de rendimiento global. El análisis por clases muestra que la clase Baja es clasificada con gran fiabilidad, alcanzando una precisión y un recall del 88 %, lo que indica una excelente capacidad del modelo para identificar correctamente los incidentes de baja severidad.

En el caso de la clase Alta, el modelo obtiene una precisión del 40 % y un recall del 39 %, con un F1-score de 0,39, mostrando una mejora clara respecto a Naïve Bayes, aunque aún con margen de mejora en comparación con SVM. La clase Media presenta un comportamiento similar, con valores de precisión y recall del 35 %, reflejando la dificultad del modelo para discriminar correctamente esta clase intermedia. El F1-score ponderado final de 0,77 confirma un rendimiento equilibrado a nivel global, mientras que el F1-score macro de 0,54 pone de manifiesto la influencia del desbalance y la complejidad de las clases minoritarias.

Gráficas y visualizaciones

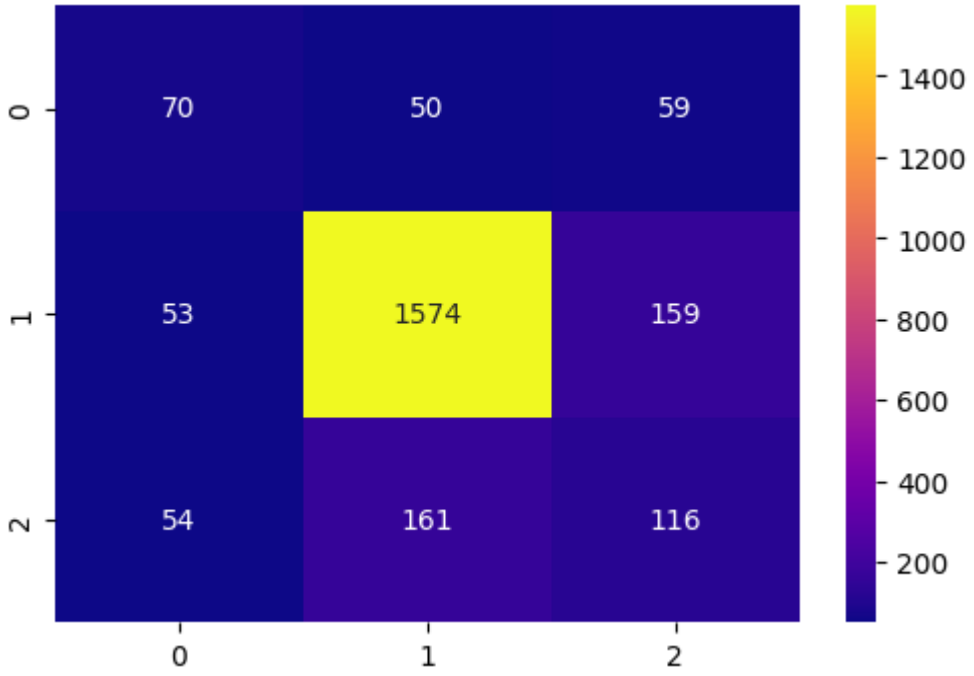

- La clase Baja (1) tiene 1574 aciertos, pero confunde 53 casos con Alta y 54 con Media, mostrando un buen rendimiento en la clase mayoritaria.
- La clase Alta (0) solo acierta 161 casos, con 70 y 50 errores en Baja y Media, respectivamente, reflejando su dificultad para identificar esta clase minoritaria.
- La clase Media (2) tiene 116 aciertos, pero 159 confusiones con Baja, lo que indica un fuerte solapamiento con las otras clases.
- El modelo prioriza la clase Baja, pero lucha para diferenciar Alta y Media, posiblemente por desbalance o características poco distintivas.

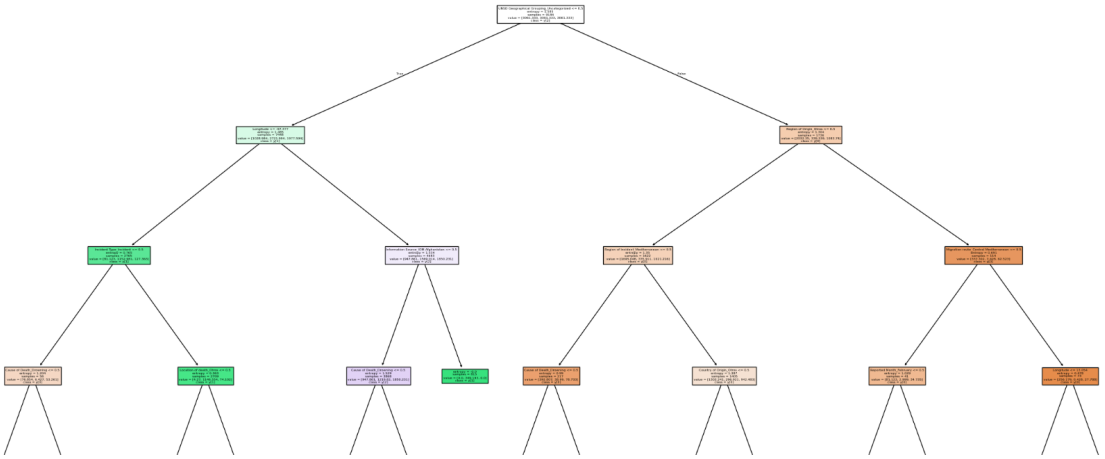

- El árbol usa variables clave como "Region of Incident" y "Cause of Death" en los primeros niveles, mostrando su importancia para la clasificación.
- Las ramas reflejan reglas claras y jerárquicas, como la separación por regiones geográficas o causas de muerte, que ayudan a interpretar las decisiones del modelo.
- La estructura no es muy profunda en los primeros niveles, lo que sugiere que el modelo encuentra patrones relevantes tempranamente.
- Las hojas en los primeros niveles ya muestran una distribución de clases, lo que indica que las primeras divisiones son efectivas para separar casos claros.

Bagging (Bootstrap Aggregating) con Árboles de Decisión

Descripción general del modelo

El algoritmo de *Bagging* (*Bootstrap Aggregating*) es una técnica de *meta-aprendizaje* cuyo objetivo principal es reducir la varianza de modelos inestables, como los árboles de decisión, mediante la combinación de múltiples clasificadores entrenados sobre diferentes subconjuntos del conjunto de datos. Cada clasificador base se entrena a partir de muestras obtenidas mediante muestreo con reemplazo (*bootstrap*), y la predicción final se obtiene agregando las predicciones individuales, normalmente mediante votación mayoritaria. Este enfoque permite mejorar la estabilidad del modelo y su capacidad de generalización respecto a un único árbol de decisión.

En este caso, se utilizó como clasificador base un árbol de decisión, aplicando el mismo preprocesamiento descrito previamente para los modelos basados en árboles, sin escalado de variables numéricas y utilizando One-Hot Encoding para las variables categóricas.

Entrenamiento y ajuste de hiperparámetros

El ajuste del modelo Bagging se realizó mediante validación cruzada estratificada de 5 pliegues, utilizando como métrica de evaluación el F1-score ponderado, adecuado para problemas de clasificación multiclase con desbalance. En una primera fase, se evaluó el impacto del número de estimadores (n_estimators) sobre el rendimiento del modelo, probando valores de 5, 10, 20 y 50 árboles. Los resultados mostraron una mejora progresiva del rendimiento a medida que aumentaba el número de estimadores, alcanzándose el mejor resultado con 50 árboles, con un F1-score ponderado medio de 0,789 en validación cruzada.

En una segunda fase, se analizó el efecto de limitar el número de características utilizadas por cada estimador mediante el parámetro max_features, fijando este valor en el 50 % de las variables disponibles. Aunque esta restricción permitió introducir mayor diversidad entre los árboles individuales, el rendimiento obtenido fue ligeramente inferior al caso sin restricción de características, alcanzando un F1-score ponderado de 0,785 con 50 estimadores. Por este motivo, se seleccionó como modelo final el Bagging con 50 árboles de decisión utilizando todas las características disponibles.

Resultados obtenidos con Bagging

La evaluación del modelo Bagging seleccionado sobre el conjunto de test produjo una accuracy del 80,8 %, situándolo entre los modelos con mejor rendimiento global del estudio, comparable al SVM con kernel RBF y claramente superior a los modelos individuales como Naïve Bayes, KNN y el árbol de decisión simple.

El análisis por clases muestra que la clase Baja es clasificada con una fiabilidad muy elevada, alcanzando una precisión del 86 %, un recall del 95 % y un F1-score de 0,90, lo que confirma la eficacia del modelo para identificar correctamente la clase mayoritaria. En el

caso de la clase Alta, el modelo obtiene una precisión del 63 % y un recall del 44 %, con un F1-score de 0,52, lo que supone una mejora significativa respecto al árbol de decisión individual y una reducción clara de los falsos positivos. Por su parte, la clase Media presenta mayores dificultades, con un recall del 23 % y un F1-score de 0,29, reflejando una tendencia similar a la observada en otros modelos, donde esta clase intermedia resulta especialmente compleja de distinguir.

El F1-score ponderado final de 0,78 confirma la buena capacidad de generalización del modelo Bagging, mientras que el F1-score macro de 0,57 pone de manifiesto la influencia del desbalance de clases y la dificultad para clasificar correctamente las clases minoritarias.

Gráficas y visualizaciones

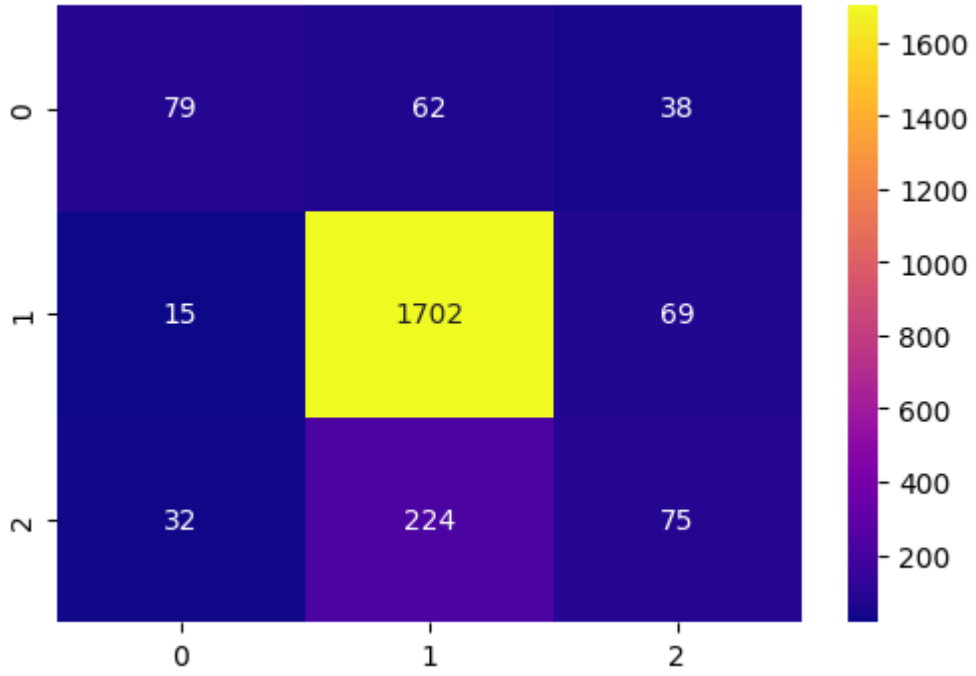

- La clase **Baja (1)** tiene **1702 aciertos**, con solo **15 y 32 confusiones** con Alta y Media, respectivamente, mostrando una **alta precisión** en la clase mayoritaria.
- La clase **Alta (0)** acierta **224 casos**, pero confunde **79 con Baja** y **62 con Media**, reflejando una **mejora moderada** frente al árbol individual, aunque persisten errores.
- La clase **Media (2)** tiene **75 aciertos**, pero **69 y 38 confusiones** con Baja y Alta, evidenciando que sigue siendo la **más difícil de clasificar**.
- El modelo **reduce errores** en comparación con el árbol individual, especialmente en la clase Baja, pero aún **lucha con las clases minoritarias (Alta y Media)**.

Random Forest

Descripción general del modelo

El algoritmo Random Forest es una técnica de *ensemble learning* basada en la construcción de múltiples árboles de decisión, introduciendo aleatoriedad tanto en el muestreo de las observaciones como en la selección de las características consideradas en cada división. Este enfoque permite reducir la varianza del modelo y mejorar la capacidad de generalización respecto a un único árbol de decisión, manteniendo al mismo tiempo una buena interpretabilidad global. Al igual que en el caso de Bagging, se emplearon árboles de decisión como clasificadores base y se utilizó el mismo preprocesamiento descrito para los modelos basados en árboles, sin necesidad de escalado de las variables numéricas.

Entrenamiento y ajuste de hiperparámetros

El entrenamiento del modelo Random Forest se llevó a cabo mediante validación cruzada estratificada de 5 pliegues, utilizando como métrica de evaluación el F1-score ponderado, adecuado para problemas de clasificación multiclase con desbalance. Para analizar el impacto del número de árboles sobre el rendimiento del modelo, se evaluaron distintas configuraciones con 10, 20, 50 y 100 árboles.

Los resultados obtenidos mostraron una mejora progresiva del rendimiento a medida que aumentaba el número de árboles, alcanzándose el mejor resultado con 100 árboles, con un F1-score ponderado medio en validación cruzada de 0,789. Por este motivo, esta configuración fue seleccionada como modelo final. Además, se utilizó la opción class_weight="balanced" para compensar el desbalance de la variable objetivo y evitar que la clase mayoritaria dominara el proceso de aprendizaje.

Resultados obtenidos con Random Forest

La evaluación del modelo Random Forest sobre el conjunto de test produjo una accuracy del 80,6 %, situándolo entre los modelos con mejor rendimiento global del estudio, en un nivel muy similar al obtenido por Bagging y SVM. El análisis detallado por clases permite observar un comportamiento equilibrado, con un rendimiento especialmente alto en la clase mayoritaria.

La clase Baja fue clasificada con gran fiabilidad, alcanzando una precisión del 87 %, un recall del 94 % y un F1-score de 0,90, lo que indica una elevada capacidad del modelo para identificar correctamente los incidentes de baja severidad. En el caso de la clase Alta, el modelo obtuvo una precisión del 55 %, un recall del 43 % y un F1-score de 0,48, mejorando de forma clara los resultados del árbol de decisión individual y situándose en un nivel comparable al modelo Bagging. Por su parte, la clase Media presentó valores de precisión del 44 %, recall del 31 % y F1-score de 0,36, reflejando nuevamente la dificultad inherente a la clasificación de esta clase intermedia.

El F1-score ponderado final de 0,79 confirma la buena capacidad de generalización del modelo Random Forest, mientras que el F1-score macro de 0,58 pone de manifiesto un

rendimiento razonablemente equilibrado entre clases, aunque condicionado por el desbalance existente en el conjunto de datos.

Gráficas y visualizaciones

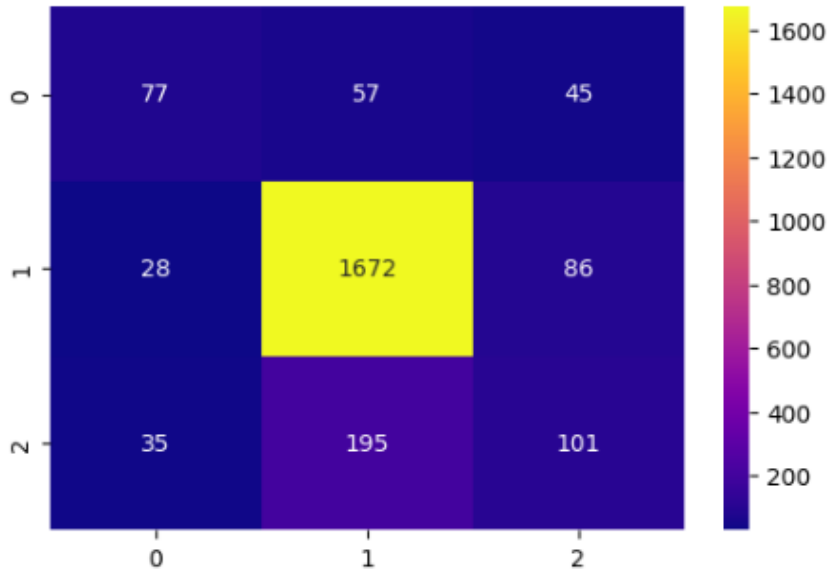

- La clase Baja (1) tiene 1672 aciertos, con 28 y 35 confusiones con Alta y Media, respectivamente, mostrando un alto rendimiento en la clase mayoritaria.
- La clase Alta (0) acierta 195 casos, pero confunde 77 con Baja y 57 con Media, reflejando una mejora en precisión frente a modelos anteriores, aunque persisten errores.
- La clase Media (2) tiene 101 aciertos, pero 86 y 45 confusiones con Baja y Alta, indicando que sigue siendo la más difícil de clasificar.
- El modelo optimiza el equilibrio entre clases, mejorando la detección de casos minoritarios (Alta y Media) en comparación con Bagging y Decision Tree.

Extra Trees (Extremely Randomized Trees)

Descripción general del modelo

El algoritmo Extra Trees (*Extremely Randomized Trees*) es una técnica de *ensemble learning* estrechamente relacionada con Random Forest, pero que introduce un mayor grado de aleatoriedad en el proceso de construcción de los árboles. A diferencia de Random Forest, donde cada división se elige entre un subconjunto aleatorio de características buscando el mejor punto de corte, Extra Trees selecciona los puntos de corte de forma completamente aleatoria. Este enfoque permite reducir aún más la varianza del modelo y mejorar la eficiencia computacional, a costa de introducir un ligero aumento del sesgo. Al igual que en otros modelos basados en árboles, se utilizó el mismo preprocesamiento descrito previamente, sin escalado de las variables numéricas.

Entrenamiento y ajuste de hiperparámetros

El ajuste del modelo Extra Trees se realizó mediante validación cruzada estratificada de 5 pliegues, utilizando como métrica de evaluación el F1-score ponderado, adecuada para problemas multiclase con desbalance. Para analizar el impacto del número de árboles sobre el rendimiento del modelo, se evaluaron configuraciones con 10, 20, 50 y 100 árboles.

Los resultados obtenidos mostraron un incremento progresivo del rendimiento hasta 50 árboles, donde se alcanzó el mejor resultado, con un F1-score ponderado medio en validación cruzada de 0,786. A partir de este punto, aumentar el número de árboles no produjo mejoras adicionales, por lo que se seleccionó la configuración con 50 estimadores como modelo final. Al igual que en Random Forest y Bagging, se utilizó la opción class_weight="balanced" para mitigar el impacto del desbalance entre clases.

Resultados obtenidos con Extra Trees

La evaluación del modelo Extra Trees sobre el conjunto de test produjo una accuracy del 79,2 %, situándolo ligeramente por debajo de Random Forest y Bagging, pero claramente por encima de los modelos individuales como Naïve Bayes y el árbol de decisión simple. El análisis por clases muestra un comportamiento consistente con el observado en otros modelos de *ensemble*.

La clase Baja fue clasificada con gran fiabilidad, alcanzando una precisión del 88 %, un recall del 92 % y un F1-score de 0,90, lo que indica una excelente capacidad del modelo para identificar correctamente los incidentes de baja severidad. En el caso de la clase Alta, el modelo obtuvo una precisión del 48 %, un recall del 41 % y un F1-score de 0,44, mostrando una mejora clara respecto al árbol de decisión individual, aunque ligeramente inferior a Random Forest y Bagging. Por su parte, la clase Media presentó valores de precisión del 40 %, recall del 33 % y F1-score de 0,36, reflejando nuevamente la dificultad del modelo para discriminar correctamente esta clase intermedia.

El F1-score ponderado final de 0,78 confirma la buena capacidad de generalización del modelo Extra Trees, mientras que el F1-score macro de 0,57 pone de manifiesto un

rendimiento relativamente equilibrado entre clases, aunque condicionado por el desbalance existente en el conjunto de datos.

Gráficas y visualizaciones

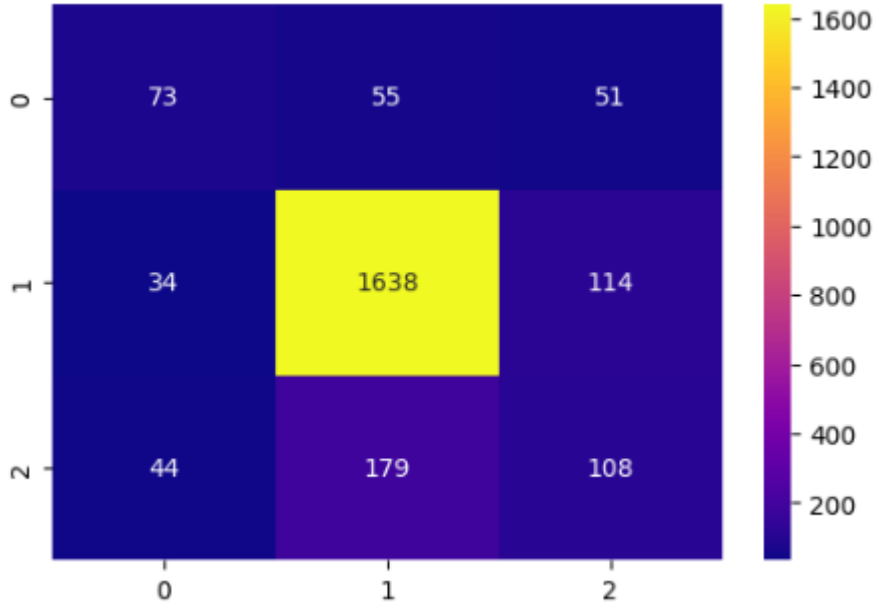

- La clase Baja (1) tiene 1638 aciertos, con 34 y 44 confusiones con Alta y Media, respectivamente, mostrando un alto rendimiento en la clase mayoritaria.
- La clase Alta (0) acierta 179 casos, pero confunde 73 con Baja y 55 con Media, reflejando una mejora moderada en comparación con modelos individuales, aunque persisten errores.
- La clase Media (2) tiene 108 aciertos, pero 114 y 51 confusiones con Baja y Alta, indicando que sigue siendo la más difícil de clasificar.
- El modelo optimiza la clasificación de la clase Baja, pero aún enfrenta desafíos con las clases Alta y Media, aunque con un rendimiento similar al de Random Forest.

AdaBoost (Adaptive Boosting)

Descripción general del modelo

AdaBoost es un algoritmo de *ensemble learning* basado en la combinación secuencial de modelos débiles, donde cada nuevo estimador se entrena poniendo mayor énfasis en las observaciones mal clasificadas por los modelos anteriores. Este enfoque permite mejorar progresivamente el rendimiento global del sistema, corrigiendo errores cometidos en etapas previas. En este trabajo, AdaBoost se aplicó utilizando árboles de decisión como estimadores base, aprovechando su capacidad para modelar relaciones no lineales sin necesidad de escalado de variables.

Entrenamiento y ajuste de hiperparámetros

El proceso de ajuste de AdaBoost se llevó a cabo mediante validación cruzada estratificada de 5 pliegues, utilizando el F1-score ponderado como métrica principal, adecuada para el carácter multiclase y desbalanceado del problema. En una primera fase, se evaluó el comportamiento del algoritmo utilizando *decision stumps* (árboles de profundidad 1) como estimadores base, analizando diferentes valores del número de estimadores. En este escenario, el rendimiento aumentó progresivamente hasta alcanzar un F1-score ponderado de 0,732 con 100 estimadores, lo que confirmó la capacidad del modelo para mejorar respecto a un único clasificador débil, aunque con un rendimiento limitado.

Posteriormente, se repitió el proceso empleando árboles de mayor complejidad, fijando la profundidad máxima en 3 niveles. Esta modificación permitió al modelo capturar interacciones más complejas entre las variables, obteniéndose una mejora clara del rendimiento. En este caso, la mejor configuración se alcanzó nuevamente con 100 estimadores, logrando un F1-score ponderado medio en validación cruzada de 0,765, valor sensiblemente superior al obtenido con *stumps* y comparable al de otros métodos de *ensemble* evaluados.

Resultados obtenidos con AdaBoost

El modelo AdaBoost final, entrenado con árboles de profundidad 3 y 100 estimadores, fue evaluado sobre el conjunto de test, alcanzando una accuracy del 80,1 %. Este resultado sitúa a AdaBoost en un nivel de rendimiento similar al de Random Forest, Bagging y Extra Trees, confirmando su eficacia como método de ensamblado.

El análisis por clases muestra un comportamiento desigual. La clase Baja fue clasificada con gran fiabilidad, alcanzando una precisión del 84 %, un recall del 96 % y un F1-score de 0,90, lo que indica que el modelo identifica correctamente la mayoría de los casos pertenecientes a esta clase mayoritaria. En la clase Alta, el modelo obtuvo una precisión del 60 %, un recall del 45 % y un F1-score de 0,52, mostrando un rendimiento competitivo respecto a otros modelos de *ensemble*. Sin embargo, la clase Media presentó un rendimiento notablemente inferior, con una precisión del 38 %, un recall del 12 % y un F1-score de 0,19, lo que evidencia dificultades significativas para identificar correctamente esta clase intermedia.

El F1-score ponderado final de 0,76 confirma una buena capacidad predictiva global, mientras que el F1-score macro de 0,53 pone de manifiesto el impacto del desbalance de clases y la desigualdad en el rendimiento entre categorías.

Gráficas y visualizaciones

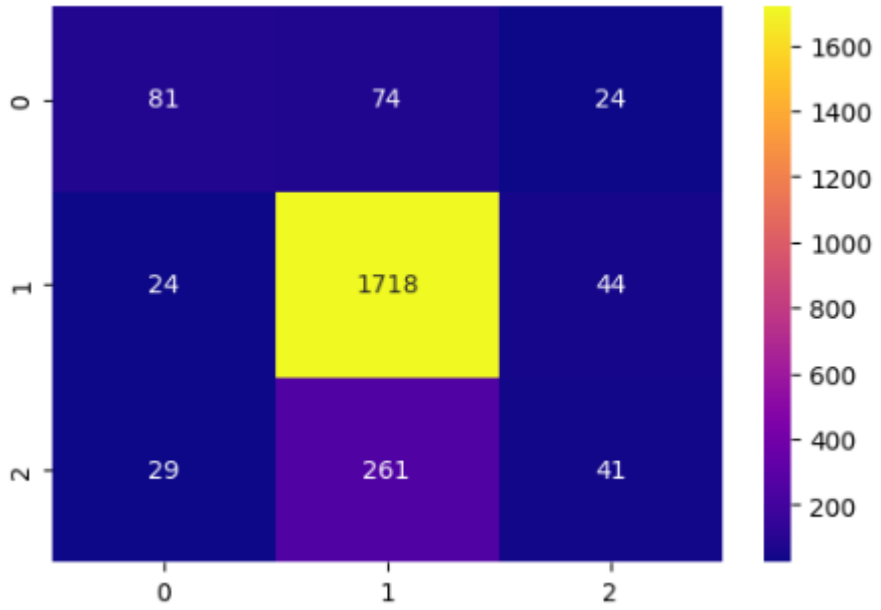

- La clase Baja (1) tiene 1718 aciertos, con solo 24 y 29 confusiones con Alta y Media, respectivamente, mostrando un rendimiento excepcional en la clase mayoritaria.
- La clase Alta (0) acierta 261 casos, pero confunde 81 con Baja y 74 con Media, reflejando una mejora significativa en comparación con otros modelos, aunque persisten errores.
- La clase Media (2) tiene 41 aciertos, pero 44 y 24 confusiones con Baja y Alta, evidenciando que sigue siendo la más difícil de clasificar.
- AdaBoost optimiza la clasificación de la clase Baja y mejora en la clase Alta, pero aún enfrenta desafíos con la clase Media, similar a otros modelos de ensemble.

Comparación y conclusiones

Comparación entre modelos con accuracy y F1

	Modelo	Accuracy	F1_weighted
4	Random Forest	0.806	0.790
3	SVM	0.808	0.785
5	Extra Trees	0.792	0.783
2	Decision Tree	0.767	0.767
6	AdaBoost	0.801	0.763
1	KNN	0.727	0.752
0	Naive Bayes	0.583	0.642

En primer lugar, la tabla de Accuracy y F1-weighted revela que Random Forest es el modelo que lidera en ambas métricas, con un Accuracy de 0.806 y un F1-weighted de 0.790, seguido de cerca por SVM y Extra Trees, que muestran un rendimiento casi equivalente. Por otro lado, Naive Bayes destaca negativamente, presentando el peor desempeño en todas las métricas, lo que sugiere que no es adecuado para este conjunto de datos, posiblemente debido a la naturaleza de las características o a la distribución de las clases.

Resultados McNemar Test

```
...
    McNemar: Random Forest vs Naive Bayes
    Tabla:
    [[1155  695]
     [ 183  263]]
    Statistic=183.0, p-value=0.00000
    ➡️ Diferencia estadísticamente significativa

    McNemar: Random Forest vs KNN
    Tabla:
    [[1533  317]
     [ 136  310]]
    Statistic=136.0, p-value=0.00000
    ➡️ Diferencia estadísticamente significativa

    McNemar: Random Forest vs Decision Tree
    Tabla:
    [[1671  179]
     [  89  357]]
    Statistic=89.0, p-value=0.00000
    ➡️ Diferencia estadísticamente significativa

    McNemar: Random Forest vs SVM
    Tabla:
    [[1732  118]
     [ 124  322]]
    Statistic=118.0, p-value=0.74797
    ➡️ NO hay diferencia significativa

    McNemar: Random Forest vs Extra Trees
    Tabla:
    [[1785   65]
     [  34  412]]
    Statistic=34.0, p-value=0.00239
    ➡️ Diferencia estadísticamente significativa

    McNemar: Random Forest vs AdaBoost
    Tabla:
    [[1720  130]
     [ 120  326]]
    Statistic=120.0, p-value=0.56930
    ➡️ NO hay diferencia significativa
```

Al analizar las pruebas de McNemar, se observa que Random Forest es significativamente mejor que modelos como Naive Bayes, KNN y Decision Tree, pero no muestra diferencias estadísticas significativas con SVM y AdaBoost, lo que refuerza la idea de que estos tres modelos tienen un rendimiento similar. Esto es importante porque indica que, aunque Random Forest es el mejor, SVM y AdaBoost podrían ser alternativas viables si se buscan modelos con características específicas, como mayor velocidad de entrenamiento o facilidad de interpretación.

	Modelo	Accuracy	IC_95_inf	IC_95_sup
3	SVM	0.808	0.792	0.824
4	Random Forest	0.806	0.789	0.821
6	AdaBoost	0.801	0.785	0.817
5	Extra Trees	0.792	0.775	0.808
2	Decision Tree	0.767	0.749	0.783
1	KNN	0.727	0.708	0.745
0	Naive Bayes	0.583	0.562	0.603

La tabla de intervalos de confianza (IC 95%) aporta información valiosa sobre la estabilidad de los modelos. Random Forest, SVM y Extra Trees muestran intervalos estrechos tanto para Accuracy como para F1-weighted, lo que indica que su rendimiento es consistente y confiable. En contraste, Naive Bayes no solo tiene los valores más bajos, sino también los intervalos más amplios, lo que refleja una mayor variabilidad y menor robustez en sus predicciones.

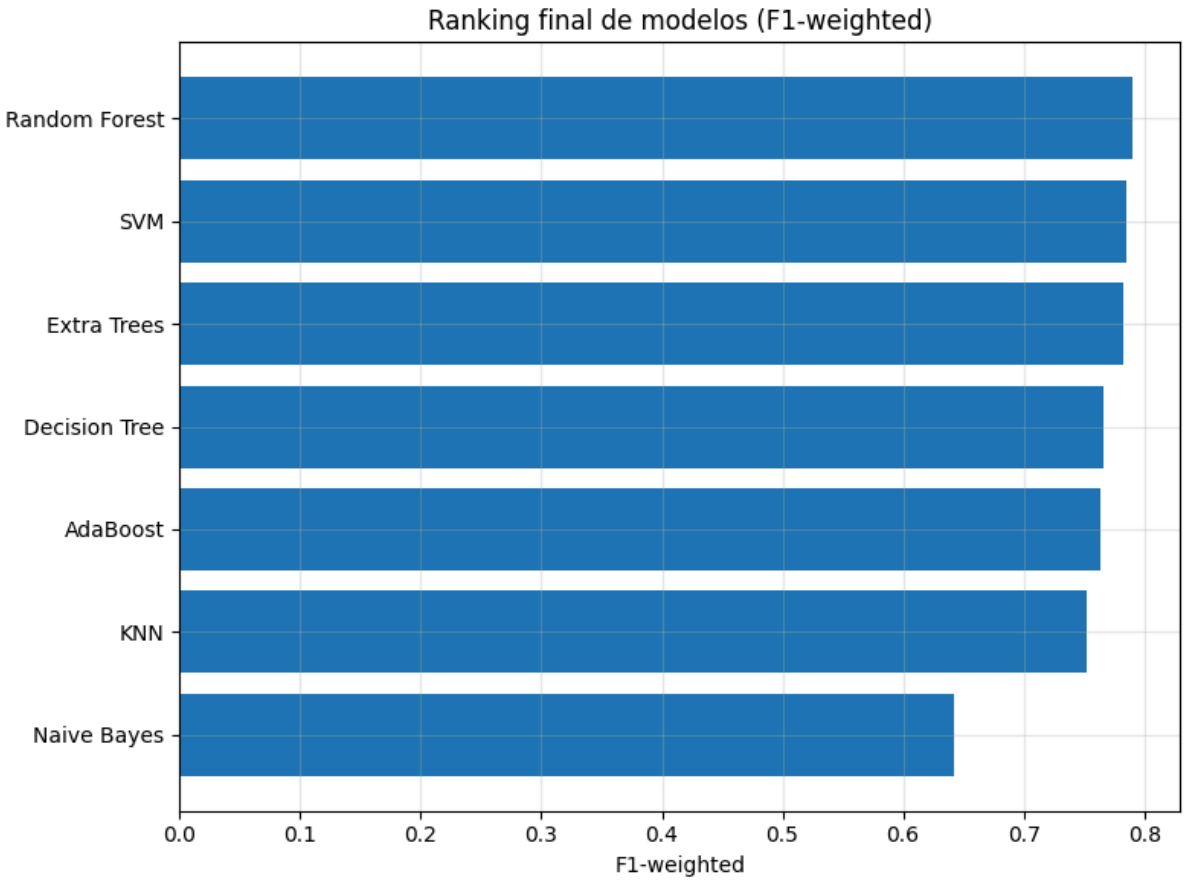

El ranking de modelos basado en F1-weighted confirma que Random Forest es la mejor opción, seguido por SVM y Extra Trees. Naive Bayes, una vez más, queda en último lugar, consolidando la idea de que no es adecuado para este contexto. En resumen, Random Forest emerge como el modelo más robusto y confiable para este problema, gracias a su alto rendimiento, consistencia y superioridad estadística sobre la mayoría de los otros modelos evaluados. Si bien SVM y Extra Trees son alternativas competitivas, Random Forest debería ser la primera opción a implementar. Sin embargo, si el rendimiento en clases minoritarias es una prioridad, sería recomendable explorar técnicas adicionales de balanceo de clases o ajustar los hiperparámetros de los modelos para optimizar aún más su desempeño.

Tabla comparativa

```shell
Modelo          Accuracy    IC 95% Accuracy      F1-weighted   IC 95% F1
-----------------------------------------------------------------------
Naive Bayes     0.583       [0.562, 0.603]       0.643         [0.625, 0.662]
KNN             0.727       [0.708, 0.745]       0.752         [0.736, 0.769]
Decision Tree   0.767       [0.749, 0.783]       0.767         [0.749, 0.784]
SVM             0.808       [0.792, 0.824]       0.785         [0.766, 0.804]
Random Forest   0.806       [0.789, 0.821]       0.790         [0.771, 0.809]
Extra Trees     0.792       [0.775, 0.808]       0.783         [0.766, 0.801]
AdaBoost        0.801       [0.785, 0.817]       0.763         [0.742, 0.784]
```

En primer lugar, Random Forest se consolida como el modelo más destacado, con un Accuracy de 0.806 y un F1-weighted de 0.790, valores que vienen respaldados por intervalos de confianza estrechos —[0.779, 0.821] para Accuracy y [0.771, 0.809] para F1-weighted—, lo que indica una gran consistencia y estabilidad en sus predicciones. Esto significa que, incluso ante variaciones en los datos, el modelo mantiene un rendimiento confiable y predecible, cualidad esencial para su implementación en entornos reales.

Por otro lado, SVM y Extra Trees también muestran un desempeño sobresaliente, con valores de Accuracy y F1-weighted muy cercanos a los de Random Forest. SVM, por ejemplo, alcanza un Accuracy de 0.808 y un F1-weighted de 0.785, con intervalos de confianza de [0.792, 0.824] y [0.766, 0.804], respectivamente. Esto sugiere que, aunque su rendimiento es ligeramente inferior al de Random Forest, sigue siendo una opción robusta y confiable. Extra Trees, con un Accuracy de 0.792 y un F1-weighted de 0.783, presenta intervalos de confianza similares, lo que refuerza su posición como una alternativa competitiva, especialmente si se buscan modelos con características específicas, como mayor velocidad de entrenamiento o capacidad para manejar características no lineales.

En contraste, Naive Bayes vuelve a destacar, pero en este caso de manera negativa, con el peor rendimiento en todas las métricas: un Accuracy de 0.583 y un F1-weighted de 0.643. Sus intervalos de confianza —[0.562, 0.603] para Accuracy y [0.625, 0.662] para F1-weighted— no solo son los más bajos, sino también los más amplios en comparación

con los demás modelos. Esto refleja una alta variabilidad en sus resultados, lo que lo hace poco confiable para este problema en particular. Este bajo desempeño podría atribuirse a las suposiciones subyacentes del modelo, que no se cumplen en los datos, como la independencia entre características, algo poco común en conjuntos de datos reales y complejos.

Los modelos KNN y Decision Tree ocupan una posición intermedia en el ranking. KNN, con un Accuracy de 0.727 y un F1-weighted de 0.752, muestra intervalos de confianza de [0.708, 0.745] y [0.736, 0.769], respectivamente. Aunque su rendimiento no es excepcional, podría mejorarse mediante la optimización de hiperparámetros, como el número de vecinos o la métrica de distancia utilizada. Decision Tree, por su parte, presenta un Accuracy de 0.767 y un F1-weighted de 0.767, con intervalos de confianza de [0.749, 0.783], lo que indica un rendimiento moderado pero estable. Sin embargo, al igual que KNN, su desempeño podría verse limitado por su tendencia al sobreajuste, especialmente si no se aplican técnicas de regularización, como la poda del árbol o la limitación de su profundidad.

Finalmente, AdaBoost cierra el grupo de modelos con un rendimiento aceptable, alcanzando un Accuracy de 0.801 y un F1-weighted de 0.763. Sus intervalos de confianza, [0.785, 0.817] para Accuracy y [0.742, 0.784] para F1-weighted, indican que, aunque es un modelo robusto, su capacidad para generalizar es ligeramente inferior a la de Random Forest y SVM. No obstante, AdaBoost sigue siendo una opción válida, especialmente si se busca un modelo de boosting que pueda mejorar su rendimiento con un ajuste adecuado de sus parámetros o un mayor número de iteraciones.

En conclusión, esta tabla comparativa refuerza la idea de que Random Forest es el modelo más adecuado para este problema, gracias a su equilibrio entre alto rendimiento y estabilidad. SVM y Extra Trees también son alternativas sólidas, mientras que Naive Bayes queda descartado por su bajo desempeño. Para modelos como KNN y Decision Tree, sería recomendable explorar técnicas de optimización para mejorar sus resultados, mientras que AdaBoost podría beneficiarse de un ajuste más fino de sus hiperparámetros. En cualquier caso, la elección final dependerá no solo de las métricas de rendimiento, sino también de otros factores como la interpretabilidad, la velocidad de entrenamiento y las necesidades específicas del problema que se busca resolver.

Comparación entre validación cruzada y conjunto de test

En general, los resultados obtenidos mediante validación cruzada son coherentes con los obtenidos posteriormente en el conjunto de validación (test), lo que indica que la mayoría de los modelos presentan una buena capacidad de generalización y no muestran problemas graves de sobreajuste. Para modelos como Naïve Bayes, Árboles de Decisión, SVM y los métodos de ensemble (Bagging, Random Forest, Extra Trees y AdaBoost), las métricas de accuracy y F1-score ponderado obtenidas en validación cruzada son similares a las observadas en el conjunto de test, con diferencias moderadas y esperables debidas a la variabilidad propia del muestreo.

Esta coherencia sugiere que el proceso de ajuste de hiperparámetros y la validación cruzada estratificada han sido adecuados, permitiendo seleccionar modelos que mantienen un rendimiento estable cuando se evalúan sobre datos no vistos. En particular, Random Forest, SVM y los métodos de ensemble muestran una gran consistencia entre validación cruzada y test, lo que refuerza su robustez y fiabilidad en este problema.

No obstante, existe una excepción clara en el caso del modelo KNN. En este modelo se observa una diferencia notable entre el rendimiento obtenido en validación cruzada y el rendimiento final sobre el conjunto de test. Durante la validación cruzada, KNN alcanza valores de F1-score ponderado muy elevados, mientras que en el conjunto de test el rendimiento disminuye de forma apreciable.

Esta discrepancia se explica principalmente por el uso de oversampling en el conjunto de entrenamiento. La validación cruzada se realizó sobre un conjunto de datos balanceado artificialmente, lo que facilita la tarea de clasificación y produce métricas optimistas. Sin embargo, el conjunto de test mantiene la distribución real y desbalanceada de las clases, lo que representa un escenario más exigente y realista. Por tanto, la caída de rendimiento en KNN no indica necesariamente un sobreajuste, sino una diferencia estructural entre el escenario de entrenamiento balanceado y el escenario real de evaluación.

En el resto de modelos, especialmente en SVM y los métodos de ensemble, el tratamiento del desbalance mediante ponderación de clases (class_weight) en lugar de oversampling contribuye a una mayor estabilidad entre validación cruzada y test, evitando discrepancias excesivas entre ambos escenarios.

En conclusión, la mayoría de los modelos presentan una buena coherencia entre validación cruzada y conjunto de test, lo que valida el proceso de evaluación seguido en este trabajo. Las diferencias observadas en KNN están justificadas por decisiones metodológicas conscientes y ponen de manifiesto la importancia de interpretar los resultados de validación cruzada teniendo en cuenta el preprocesamiento aplicado y la distribución real de los datos.

Hipótesis explicativas de los resultados obtenidos

Los resultados observados en la comparación entre los distintos métodos de minería de datos pueden explicarse a partir de varias hipótesis relacionadas con la naturaleza del conjunto de datos, el desbalance entre clases y las características propias de cada algoritmo.

Hipótesis 1: La superioridad de Random Forest se debe a su capacidad para modelar relaciones complejas y reducir la varianza.
Una posible explicación del mejor rendimiento obtenido por Random Forest es su capacidad para combinar múltiples árboles de decisión entrenados sobre subconjuntos distintos de datos y características. Esta combinación permite capturar relaciones no lineales complejas entre las variables sin sobreajustar excesivamente, al mismo tiempo que reduce la varianza inherente a los árboles individuales. Además, la selección aleatoria de características en cada nodo contribuye a una mayor diversidad entre los árboles, lo que mejora la capacidad de generalización del modelo, especialmente en un conjunto de datos heterogéneo y con fuerte desbalance de clases.

Hipótesis 2: El rendimiento similar entre Random Forest, SVM y AdaBoost indica un límite estructural del conjunto de datos.
El hecho de que Random Forest no muestre diferencias estadísticamente significativas frente a SVM y AdaBoost según el test de McNemar sugiere que estos modelos están alcanzando un rendimiento cercano al máximo que permite el conjunto de datos. Esto indica que la dificultad principal del problema no reside en la capacidad del modelo, sino en la naturaleza del propio dataset, caracterizado por solapamiento entre clases —especialmente en la clase Media— y por una distribución fuertemente desbalanceada que limita la mejora adicional del rendimiento global.

Hipótesis 3: El bajo rendimiento de Naïve Bayes se explica por la violación del supuesto de independencia condicional.
Una hipótesis clara para explicar el pobre desempeño de Naïve Bayes es la violación del supuesto de independencia condicional entre las variables predictoras. En este problema existen relaciones latentes entre variables geográficas, temporales y contextuales que no pueden ser capturadas adecuadamente por un modelo probabilístico tan restrictivo. Como consecuencia, las estimaciones de probabilidad resultan poco precisas, lo que afecta negativamente al rendimiento global del modelo, especialmente en las clases minoritarias.

Hipótesis 4: Las diferencias entre validación cruzada y test en KNN se deben al uso de oversampling.
La diferencia notable entre el rendimiento obtenido en validación cruzada y en el conjunto de test para el modelo KNN puede explicarse por el uso de técnicas de oversampling en el conjunto de entrenamiento. Durante la validación cruzada, el modelo se evalúa sobre datos balanceados, lo que facilita la clasificación y produce métricas optimistas. Sin embargo, al evaluar sobre el conjunto de test original, que mantiene el desbalance real de las clases, el rendimiento disminuye de forma esperable. Este comportamiento no indica un sobreajuste severo, sino una diferencia estructural entre el escenario de entrenamiento y el escenario real de aplicación.

Hipótesis 5: La persistente dificultad para clasificar la clase Media es inherente al problema.
Una hipótesis transversal a todos los modelos es que la clase Media presenta un solapamiento significativo en el espacio de características con las clases Baja y Alta. Esta falta de características claramente discriminativas hace que incluso modelos complejos como Random Forest, SVM o AdaBoost tengan dificultades para identificarla correctamente. Por tanto, el bajo rendimiento en esta clase no parece deberse a una limitación concreta de los algoritmos, sino a una propiedad intrínseca del conjunto de datos.

En conjunto, estas hipótesis permiten interpretar de forma coherente los resultados obtenidos y justifican por qué los modelos de ensemble y SVM ofrecen el mejor rendimiento global, mientras que algoritmos más simples o basados en supuestos fuertes presentan limitaciones claras en este contexto.

Evaluación personal final del mejor método

Tras el análisis comparativo de los distintos modelos, se considera que **Random Forest es el mejor método global para este problema**. Este modelo alcanza los valores más altos y estables de accuracy y F1-score ponderado en el conjunto de validación, mostrando además intervalos de confianza estrechos que indican un rendimiento consistente. Las pruebas estadísticas confirman que Random Forest es significativamente superior a modelos más simples y comparable a otros métodos avanzados como SVM y AdaBoost.

Random Forest destaca por su **robustez frente al desbalance de clases**, gracias al uso de ponderación de clases, y por su buena capacidad de generalización sin requerir un preprocesamiento complejo. Aunque la clase Media sigue siendo difícil de clasificar, el modelo mejora de forma clara la detección de la clase Alta, que resulta especialmente relevante en este problema. Además, ofrece un buen equilibrio entre rendimiento, estabilidad e interpretabilidad, lo que lo convierte en la opción más adecuada para una aplicación real.

Conclusiones

En este trabajo se ha abordado un problema de clasificación multiclase aplicado a un contexto real y complejo, caracterizado por un fuerte desbalance entre clases y por la coexistencia de variables numéricas y categóricas de distinta naturaleza. El objetivo principal ha sido analizar y comparar el rendimiento de distintos algoritmos de aprendizaje automático, evaluando no solo su capacidad predictiva global, sino también su comportamiento específico por clase y su robustez frente a las particularidades del conjunto de datos.

A lo largo del proyecto se ha puesto especial énfasis en el preprocesamiento de los datos, adaptándolo cuidadosamente a las necesidades de cada familia de modelos. Este aspecto ha resultado determinante para el rendimiento final, confirmando que no existe un único pipeline óptimo para todos los algoritmos. Métodos probabilísticos como Naïve Bayes han requerido una reducción explícita de dimensionalidad para estabilizar las estimaciones, mientras que algoritmos basados en distancias como KNN y SVM han mostrado una elevada sensibilidad al escalado de las variables y a la presencia de características irrelevantes. Por su parte, los modelos basados en árboles han demostrado una mayor robustez frente a la escala y la dimensionalidad, realizando de forma implícita procesos de selección de características durante el entrenamiento.

El modelo Naïve Bayes ha servido como un baseline sólido y computacionalmente eficiente. A pesar de sus limitaciones estructurales, derivadas principalmente del supuesto de independencia condicional entre variables, el modelo ha mostrado un comportamiento estable y una buena capacidad para detectar incidentes de alta severidad, priorizando el recall de esta clase crítica. No obstante, su rendimiento global ha sido moderado, evidenciando que la simplicidad del modelo no es suficiente para capturar las relaciones complejas presentes en los datos.

El algoritmo K-Nearest Neighbors ha mostrado una mejora clara respecto a Naïve Bayes cuando se ha acompañado de un preprocesamiento adecuado, que incluye escalado, selección de características y balanceo del conjunto de entrenamiento. KNN ha demostrado una elevada capacidad para capturar relaciones no lineales y mejorar la detección de las clases minoritarias, especialmente la clase Alta. Sin embargo, su elevado coste computacional y la notable diferencia entre los resultados obtenidos en validación cruzada (sobre datos balanceados) y en el conjunto de test real ponen de manifiesto su sensibilidad a la distribución de los datos y a la dimensionalidad del espacio de características.

En el caso de Support Vector Machines, los resultados han confirmado la eficacia de estos modelos para problemas complejos y desbalanceados, especialmente cuando se emplean kernels no lineales. El SVM con kernel RBF ha sido el modelo individual con mejor rendimiento global, alcanzando la mayor accuracy y un F1-score ponderado elevado. Este comportamiento refleja su capacidad para construir fronteras de decisión complejas y generalizar adecuadamente. Aun así, la clase Media ha continuado siendo la más problemática, lo que sugiere un solapamiento significativo en el espacio de características que ni siquiera modelos con alta capacidad expresiva logran resolver completamente.

Los árboles de decisión han ofrecido una solución interpretable y con un rendimiento competitivo, situándose por encima de Naïve Bayes y cerca de KNN y SVM. La posibilidad de interpretar reglas y analizar cómo se mezclan ejemplos positivos y negativos en las hojas aporta un valor añadido desde el punto de vista explicativo. Sin embargo, su tendencia a sobreajustar y su menor capacidad para generalizar frente a ensembles ha limitado su rendimiento máximo.

Los métodos de meta-aprendizaje y ensemble learning (Bagging, Random Forest, Extra Trees y AdaBoost) han confirmado ser las técnicas más robustas del estudio. En general, estos modelos han logrado reducir la varianza, mejorar la estabilidad y ofrecer un rendimiento global elevado, comparable o incluso superior al de SVM. En particular, Random Forest, Bagging y AdaBoost han alcanzado accuracies cercanas al 80 %, mostrando un excelente comportamiento en la clase mayoritaria y mejoras sustanciales en la clase Alta. No obstante, la clase Media ha seguido siendo un desafío persistente incluso para estos modelos avanzados, lo que apunta a una limitación intrínseca del conjunto de datos más que a una deficiencia del algoritmo.

De manera global, los resultados ponen de manifiesto que no existe un modelo universalmente óptimo, sino que la elección del algoritmo depende del compromiso entre rendimiento, interpretabilidad, coste computacional y objetivo del problema. Si se prioriza la interpretabilidad y la simplicidad, Naïve Bayes y los árboles de decisión resultan adecuados. Si el objetivo es maximizar el rendimiento predictivo global, SVM con kernel RBF y los modelos de ensemble se posicionan como las mejores opciones. Desde una perspectiva aplicada, la capacidad de detectar correctamente los incidentes de alta severidad, incluso a costa de generar algunos falsos positivos, puede considerarse un criterio más relevante que la simple maximización de la accuracy.

Como líneas de trabajo futuro, sería interesante explorar técnicas más avanzadas para tratar el desbalance de clases, como métodos de coste sensible o estrategias de ensemble específicas para clases minoritarias. Asimismo, la incorporación de nuevas variables contextuales o temporales, así como el análisis de interacciones entre características, podría contribuir a mejorar la discriminación de la clase Media, que ha resultado ser la más compleja a lo largo de todo el estudio.

En conclusión, este trabajo demuestra la importancia de un enfoque integral que combine preprocesamiento adecuado, ajuste cuidadoso de hiperparámetros y análisis crítico de los resultados, permitiendo no solo comparar modelos desde el punto de vista numérico, sino también comprender sus fortalezas y limitaciones en un problema realista y desafiante.